



Politechnika Wrocławska

Wydział Informatyki i Zarządzania

Kierunek studiów: Informatyka

Specjalność: Inteligentne Systemy Informatyczne

Praca dyplomowa - magisterska

ALGORYTMY EWOLUCYJNE Z UWZGLĘDNIENIEM  
PŁCI W ROZWIĄZYWANIU WYBRANYCH  
PROBLEMÓW

Filip Malczak

słowa kluczowe:  
algorytmy ewolucyjne  
płeć  
operator selekcji

krótkie streszczenie:

Bardzo krótkie streszczenie w którym powinno się znaleźć omówienie tematu pracy i poruszanych terminów. Tekst ten nie może być zbyt długi.

Promotor:	.....	.....	.....
	<i>imię i nazwisko</i>	<i>ocena</i>	<i>podpis</i>

Wrocław 2015

# Spis treści

<b>Rozdział 1. Wprowadzenie</b>	<b>1</b>
1.1. Algorytmy ewolucyjne . . . . .	1
1.2. Cele pracy . . . . .	2
<b>Rozdział 2. Algorytmy ewolucyjne</b>	<b>5</b>
2.1. Idea algorytmów ewolucyjnych . . . . .	5
2.2. Formalny opis operatorów i parametrów . . . . .	9
2.2.1. Konwencje . . . . .	10
2.2.2. Pojęcie operatora . . . . .	12
2.2.3. Osobnik, populacja i ocena . . . . .	13
2.2.4. Operator mutacji . . . . .	14
2.2.5. Operator krzyżowania . . . . .	14
2.2.6. Operator selekcji . . . . .	15
2.2.7. Warunek stopu . . . . .	15
2.3. Szczegóły działania heurystyki . . . . .	16
2.4. Analiza jakości działania . . . . .	18
2.4.1. Analiza jednego przebiegu heurystyki . . . . .	18
2.4.2. Analiza wielu przebiegów heurystyki . . . . .	21
<b>Rozdział 3. Przegląd literatury</b>	<b>23</b>
<b>Rozdział 4. Proponowane rozwiązania</b>	<b>25</b>
4.1. Heurystyka DSEA . . . . .	25
4.1.1. Działanie . . . . .	26
4.1.2. Operator selekcji naturalnej . . . . .	29
4.1.3. Operator selekcji płciowej . . . . .	30
4.1.4. Realizacja wybranych operatorów selekcji płciowej . . . . .	32
4.2. Proponowany operator selekcji płciowej . . . . .	35
<b>Rozdział 5. Eksperymenty</b>	<b>39</b>
5.1. Wybrane problemy optymalizacji . . . . .	39
5.2. Implementacja . . . . .	40
5.2.1. Komponenty niezależne od problemu . . . . .	40
5.2.2. Implementacja problemu komiwojażera . . . . .	44
5.2.3. Implementacja problemu plecakowego . . . . .	46
5.3. Procedury eksperymentów . . . . .	49
5.4. Przeprowadzone eksperymenty . . . . .	49
5.4.1. Badania problemu komiwojażera . . . . .	51

<i>SPIS TREŚCI</i>	iii
5.4.2. Badania problemu plecakowego . . . . .	58
<b>Rozdział 6. Wnioski i spostrzeżenia</b>	<b>67</b>
<b>Rozdział 7. Dalsze drogi rozwoju</b>	<b>69</b>
<b>Spis sygnatur</b>	<b>73</b>
<b>Spis algorytmów</b>	<b>75</b>
<b>Bibliografia</b>	<b>77</b>
<b>Dodatek A. Pełne wyniki badań</b>	<b>79</b>
A.1. Oceny uruchomień . . . . .	79
A.2. Średnia i odchylenie standardowe ocen . . . . .	79
A.2.1. Problem komiwojażera . . . . .	79
A.2.2. Problem plecakowy . . . . .	83

Abstrakt

**Streszczenie**

Abstrakt

**Abstract**

## Rozdział 1

# Wprowadzenie

Optymalizacja to zadanie wyboru najlepszego elementu z danego zbioru (nazywanego przestrzenią rozwiązań). Przez najlepszy rozumiemy taki, dla którego tzw. funkcja oceny, czy też kryterium przyjmuje najwyższą (w zadaniu maksymalizacji) lub najniższą (w zadaniu minimalizacji) wartość. Z takim problemem spotykamy się wszędzie tam, gdzie chcemy zwiększyć lub zmniejszyć jakieś wskaźniki, np. zminimalizować koszt produkcji lub transportu, albo zmaksymalizować zyski ze sprzedaży lub jakość klasyfikacji.

Jeżeli funkcję oceny można zapisać w postaci analitycznej (np. w formie układu równań różniczkowych) to zazwyczaj możemy ją optymalizować metodami numerycznymi, analitycznymi lub algebraicznymi. Istnieją sytuacje, w których nie możemy skorzystać z żadnej z tych metod. Powody tego mogą być różne, m.in. możemy nie znać postaci funkcji (bo np. reprezentuje ona obserwacje jakiegoś procesu lub zjawiska), funkcja zapisana analitycznie może nie spełniać pewnych kryteriów (np. nie być różniczkowalna), lub obliczenia mogą zajmować zbyt wiele czasu (np. pełne przeszukiwanie przestrzeni rozwiązań będącej iloczynem kartezjańskim dużej liczby dużych, czy wręcz nieskończonych zbiorów). Często nie jest nam potrzebne globalne optimum (tzn. najlepsze rozwiązanie ze wszystkich możliwych), a wystarczy rozwiązanie jak najlepsze (tzn. optimum lokalne, lub punkt o wartości kryterium zbliżonej do wartości kryterium optimum globalnego).

Do takich zastosowań przeznaczone są metody nazywane heurystykami. W zależności od źródła definicje tego pojęcia są różne. W dziedzinie informatyki, a w szczególności obliczeń miękkich i sztucznej inteligencji, termin ten możemy nieformalnie opisać jako algorytm który nie daje gwarancji uzyskania poprawnego wyniku, ale z większym prawdopodobieństwem zwróci wyniki „lepsze”. Heurystyki stosowane są wszędzie tam, gdzie nie mamy rzeczywistej możliwości uzyskania wyniku, więc dowolne jego przybliżenie będzie lepsze niż brak jakichkolwiek rezultatów.

### 1.1. Algorytmy ewolucyjne

Ewolucja to proces zachodzący w naturze odpowiedzialny za dopasowywanie się osobników danego gatunku do środowiska w jakim żyją. Podstawą tego procesu jest

zasada przetrwania lepiej przystosowanych osobników oraz zjawiska dziedziczenia i mutacji.

Zgodnie z powyższą zasadą, jednostki lepiej dopasowane do środowiska mają większą szansę na przeżycie, a co za tym idzie, na wydanie potomstwa. Oznacza to, że rodzice większości osobników z kolejnego pokolenia będą radzić sobie w tym środowisku lepiej niż pozostała część populacji.

Zjawisko dziedziczenia polega na przekazywaniu cech rodziców dzieciom. Zachodzi ono podczas rozmnażania, a więc między dwojgiem rodziców i ich potomstwem. Kod genetyczny potomstwa tworzony jest przez losowe łączenie odpowiednich części kodu genetycznego rodziców, dzięki czemu kolejne pokolenie dzieli ich cechy. W ten sposób niektóre osobniki przejmą od rodziców te cechy, które pozwalały im się dopasować do środowiska. Część osobników przejmie jednak nie tylko cechy poprawiające ich szansę przetrwania, ale również cechy negatywne, co przełoży się na ich gorsze dopasowanie.

Mutacja to zjawisko zachodzenia losowych zmian w kodzie genetycznym osobnika, dzięki którym ma on szansę zyskać nowe cechy, co w niektórych przypadkach doprowadzi do lepszego dopasowania. Osobniki z przypadkowymi zmianami, które poprawiają ich dopasowanie mają większe szanse na przeżycie i wydanie potomstwa. Zmiany te więc zostać rozpropagowane wśród osobników przyszłych pokoleń.

Algorytmy ewolucyjne to rodzina heurystyk naśladujących proces ewolucji w celu optymalizacji [5]. Pojedynczy element przestrzeni rozwiązań jest w nich nazywany osobnikiem. Osobniki możemy między sobą porównywać pod względem wartości optymalizowanej funkcji dla nich, a relacja mniejszości (dla problemów minimalizacji) lub większości (dla problemów maksymalizacji) reprezentuje relację bycia lepiej przystosowanym do środowiska. Ponadto, na osobnikach określone są operatory mutacji i krzyżowania, które mają na celu symulację odpowiednich zjawisk występujących w przyrodzie. Heurystyka polega na wielokrotnym przetworzeniu populacji (czyli zbioru osobników) poprzez zastosowanie każdego z operatorów z pewnym prawdopodobieństwem. W każdym kroku (nazywanym w tym przypadku pokoleniem) do dotychczasowej populacji dołączane są wyniki ich działania tych operatorów, a następnie wybierana jest nowa populacja, używana w kolejnym kroku. Aby odwzorować zasadę przetrwania najlepiej dopasowanych osobników, do kolejnej populacji wybierane są z wyższym prawdopodobieństwem osobniki lepiej przystosowane.

W naturze rozmnażanie się osobników wielu gatunków jest ściśle związane ze zjawiskiej podziału gatunku na płcie. Bardziej szczegółowy opis tego zjawiska znajduje się w rozdziale 4. W dostępnej literaturze dotyczącej tematu algorytmów ewolucyjnych rzadko można znaleźć prace, w których uwzględnia się ten aspekt procesu ewolucji (patrz: rozdział 3). Powodem tego jest raczej chęć uproszczenia działania samej heurystyki niż lepsza jakość wyników uzyskiwanych z pominięciem tego aspektu ([7], [9]).

## 1.2. Cele pracy

Pierwszym celem niniejszej pracy jest opracowanie formalnego opisu algorytmu ewolucyjnego uwzględniającego płcie. Schemat heurystyki jest w pewnym stopniu dowolny, a publikacje z tej dziedziny nie używają jednego wspólnego formalizmu, co utrudnia jednoznaczne porównywanie ich działania. Spełnienie tego celu powinno doprowadzić

do określenia konkretnego schematu, który pozwoli zaimplementować wybrane istniejące rozwiązania oraz zaproponowane rozwiązanie autorskie.

Kolejnym celem jest opis i implementacja wybranych istniejących rozwiązań wykorzystujących płęć w ramach wcześniej opisanego schematu. Poza implementacją tych metod, powinno powstać narzędzie badawcze, które pozwoli na klarowne porównanie ich działania.

Cel trzeci to opracowanie i implementacja nowego podejścia uwzględniającego płęć. Jest to główny cel tej pracy, mający wniesć coś nowego do dziedziny algorytmów ewolucyjnych.

Ostatnim celem jest zbadanie wcześniej opisanych i zbadanych podejść. Polega to na zebraniu miar jakości działania algorytmów ewolucyjnych dla każdego z nich i porównaniu ich ze sobą.





## Rozdział 2

# Algorytmy ewolucyjne

Ten rozdział ma na celu opisanie zagadnienia algorytmów ewolucyjnych, zaczynając od ogólnych informacji, stopniowo przechodząc do szczegółów. W pierwszej jego części opisana jest ogólna idea tych heurystyk. Kolejna sekcja skupia się na formalnym opisie poszczególnych pojęć. Po niej znajduje się część w której znajdziemy szczegóły idei opisanej na początku, zapisane z użyciem pojęć przedstawionych w sekcji drugiej. Całość zostanie zamknięta opisem sposobów oceny i analizy działania algorytmów ewolucyjnych.

### 2.1. Idea algorytmów ewolucyjnych

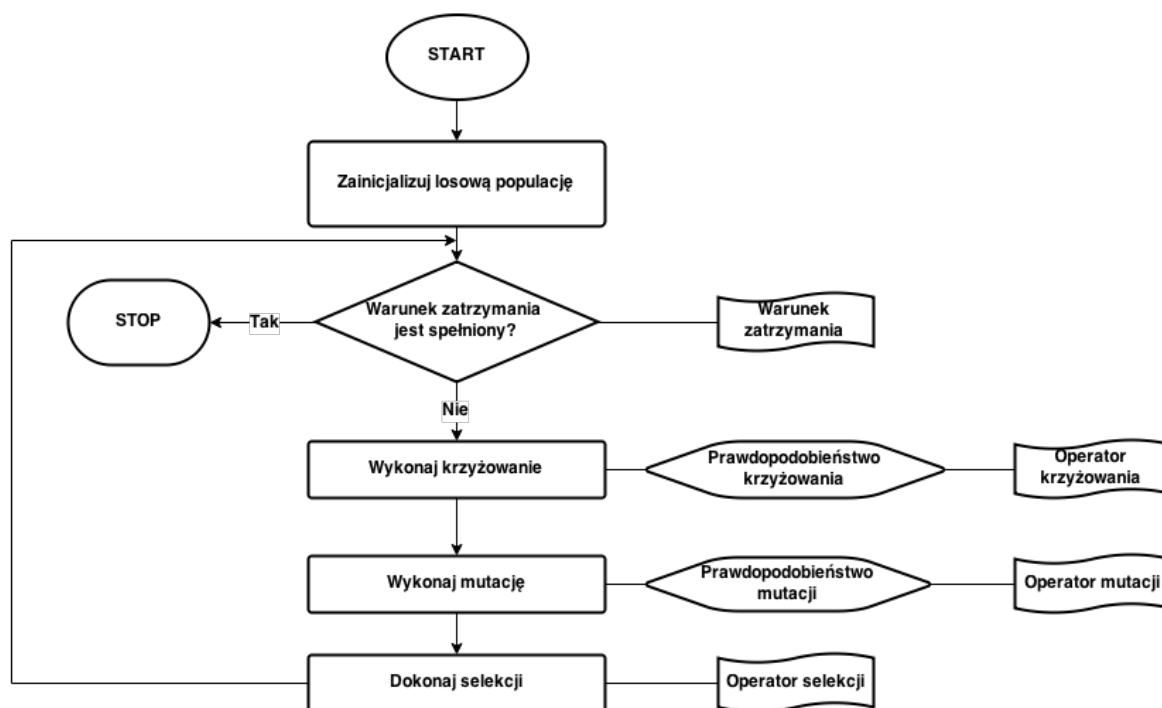
Podstawowym pojęciem używanym w opisywanej heurystyce jest *osobnik*. Jest to abstrakcja pojedynczego rozwiązania, nawiązująca do pojedynczego żywego stworzenia charakteryzującego się pewnymi cechami które wpływają na prawdopodobieństwo jego przeżycia i wydania potomstwa. Pojęciem symulującym wpływ cech na prawdopodobieństwo przeżycia jest *funkcja oceny*. Dodatkowo wprowadzamy pojęcie *populacji*, czyli zbioru osobników istniejących w danym momencie w procesie ewolucji.

Realizacją osobnika w heurystyce jest reprezentacja rozwiązania problemu, a realizacją populacji - zbiór rozwiązań, czyli podzbiór przestrzeni rozwiązań. Populację możemy też rozumieć jako zbiór próbek z pewnej podprzestrzeni zbioru rozwiązań.

Przez pojęcie funkcji oceny (nazywanej też kryterium) rozumiemy pewne przyporządkowanie (w idealnej sytuacji - funkcję, jednak nie zawsze jest to możliwe; patrz: rozdział 2.2.3) każdemu osobnikowi, czyli rozwiązaniu problemu, jakiejś wartości, na której możemy określić porządek. Taka relacja porządku powinna określać czy dane rozwiązanie jest równie dobre lub lepsze niż inne, czy nie.

Standardową realizacją osobnika jest wektor binarny, który sprawdza się w wielu zastosowaniach i jest prosty w realizacji programowej lub sprzętowej. Algorytmy ewolucyjne korzystające z takiej reprezentacji nazywane są algorytmami genetycznymi. Reprezentacja jest jednak uzależniona od rozwiązywanego problemu. Często wykorzystuje się bardziej skomplikowane przedstawienia rozwiązania, jak wektor wartości z pewnego zbioru (skończonego, lub nieskończonego, jak liczby), czy drzewo [4] (np. dla problemów

Rys. 2.1. Ogólny schemat działania algorytmów ewolucyjnych



Konwencje dotyczące rysowania schematów blokowych zostały wyjaśnione w podsekcji 2.2.1.

aproksymacji funkcji, przedstawionych jako zadanie minimalizacji błędu przybliżenia [8]).

Istnieją implementacje i narzędzia do obliczeń ewolucyjnych które rozróżniają pojęcie genotypu osobnika (czyli wewnętrznej reprezentacji rozwiązania, na której stosujemy operatory genetyczne takie jak krzyżowanie i mutacja) i jego fenotypu (czyli reprezentacji zewnętrznej, na podstawie której oceniamy osobnika), jednak jest to jedynie abstrakcja umożliwiającą czytelniejsze zapisanie realizacji odpowiednich pojęć w języku programowania. Niniejsza praca nie wprowadza takiego rozróżnienia, ponieważ nie zmienia ono w żadnym stopniu jakości działania heurystyki i nie jest związane z tematem badań.

Na rysunku 2.1 zobrazowany został ogólny schemat działania algorytmów ewolucyjnych. Formalny opis używanych parametrów i operatorów znajduje się w kolejnej sekcji, wraz z definicją takich pojęć jak np. operator.

Współczesna nauka dalej nie jest w stanie dać nam odpowiedzi na pytanie „skąd wzięło się życie”, a co za tym idzie, nie jesteśmy w stanie zasymulować momentu rozpoczęcia ewolucji. Zamiast tego, w heurystykach naśladujących ten proces działanie zaczyna się od wygenerowania losowej populacji, czyli zbioru osobników. Symuluje to w uproszczony sposób analizę ewolucji od przypadkowego momentu w czasie istnienia gatunku. Biorąc pod uwagę, że celem heurystyki nie jest idealnie wierne odtworzenie warunków naturalnych, a optymalizacja, nie wydaje się to być problemem.

Mając zbiór początkowych osobników (czyli rozwiązań naszego problemu) rozpoczynamy proces przeszukiwania ich przestrzeni. Dzieje się to iteracyjnie, co znaczy,

że pewien zestaw kroków jest wielokrotnie powtarzany. Jedno takie powtórzenie jest nazywane *generacją* lub *pokoleniem*, a składa się na nie kolejno krzyżowanie, mutacja i selekcja naturalna. Moment w którym należy przerwać proces optymalizacji jest wybierany przez kryterium przerwania. Nie ma to przełożenia na naturę (jako, że ewolucja teoretycznie nigdy się nie kończy) i jest jedynie narzędziem które ma sprawić, że heurystyka nie będzie działać wiecznie, tylko w skończonym czasie zwróci interesujące nas wyniki.

Na pojedyncze pokolenie składają się 3 główne kroki: krzyżowanie, mutacja i selekcja. Mają one symulować odpowiednie zjawiska występujące w przyrodzie - kolejno dziedziczenie, mutację i przetrwanie lepiej dopasowanych osobników. Pierwsze dwa z nich kontrolują tempo przeszukiwania przestrzeni rozwiązań, a ostatnie steruje przeszukiwaniem tak, aby odnajdywać jak najlepsze rozwiązania.

Krzyżowanie odbywa się przy pomocy dedykowanego operatora, z częstością określoną odpowiednim prawdopodobieństwem. Polega ono na wybraniu losowych par osobników nazywanych rodzicami i dołączeniu do populacji nowych rozwiązań (nazywanych potomstwem), o reprezentacji zbliżonej do reprezentacji rodziców. Ma to symulować dziedziczenie cech rodziców przez ich potomków. Zadaniem krzyżowania jest eksploatacja przestrzeni rozwiązań, poprzez zbadanie punktów, które znajdują się pomiędzy znanymi nam już rozwiązaniami. Dzięki temu zagęszczamy próbkowanie podprzestrzeni, którą już zbadaliśmy, czyli dotychczasowej populacji, co ma na celu znalezienie potencjalnych optimumów, które mogły zostać przeoczone przez zbyt rzadkie próbkowanie.

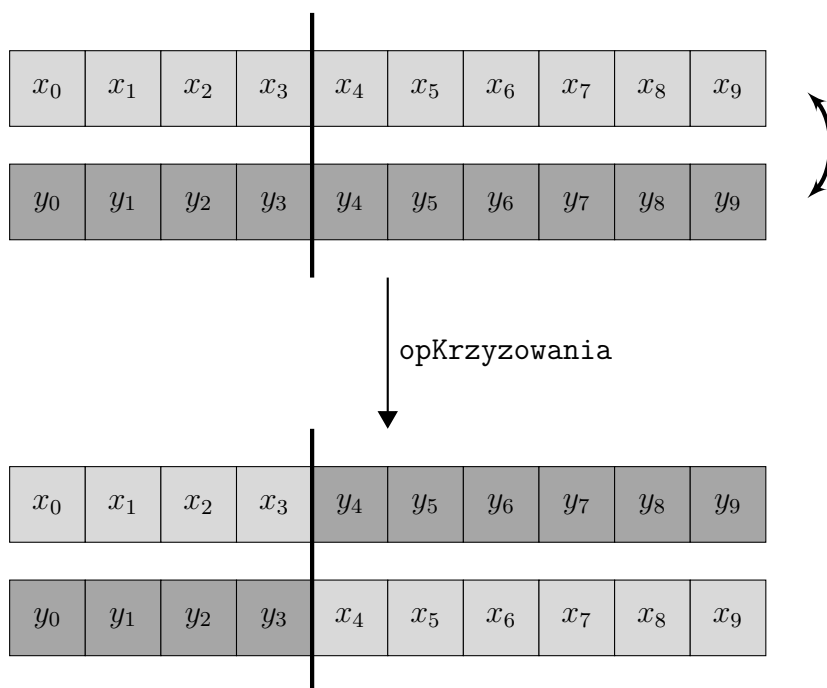
Jedną z popularnych realizacji operatora krzyżowania dla osobnika reprezentowanego jako wektor jest wybranie losowej pozycji w wektorach opisujących rodziców (tzw. punktu przecięcia) i zwrócenie 2 osobników powstałych przez zamianę podwektorów od wylosowanej pozycji wzwyż. Na rysunku 2.2 zobrazowano działanie takiego podejścia. Wektory  $(x_0, \dots, x_9)$  i  $(y_0, \dots, y_9)$  to przykładowi rodzice. Grubą linią zaznaczono wylosowany punkt przecięcia, wyznaczający podwektory które zostają zamienione. Wektory  $(x_0, \dots, x_3, y_4, \dots, y_9)$  i  $(y_0, \dots, y_3, x_4, \dots, x_9)$  są wtedy traktowane jako potomstwo.

Kolejnym krokiem w każdym pokoleniu jest mutacja, czyli wprowadzenie losowych zmian w losowo wybranych osobnikach. Jest to wykonywane przy pomocy odpowiedniego operatora, z prawdopodobieństwem określającym szansę osobnika na zmutowanie. Zmodyfikowane osobniki w zależności od implementacji są dołączane do populacji, albo zastępują niezmodyfikowane rozwiązania. W tej pracy wykorzystano pierwszą z tych opcji, aby nie doprowadzić do sytuacji, w której mutacja pogorszy znane rozwiązanie, które zostanie odrzucone z populacji (ponieważ na jego miejsce wejdzie rozwiązanie zmodyfikowane). Zadaniem tego kroku jest eksploracja przestrzeni rozwiązań, czyli zbadanie rozwiązań spoza dotychczas spróbkowanej podprzestrzeni. W ten sposób heurystyka przeszukuje nowe obszary, które potencjalnie zawierają optimum globalne, a przynajmniej optima lokalne lepsze od dotychczas znalezionych.

Jedną z popularnych realizacji operatora mutacji dla osobnika reprezentowanego jako wektor bitów jest negacja losowych wartości, w wyniku czego otrzymujemy osobniki różniące się od argumentu operatora tylko kilkoma elementami. Na rysunku 2.3 zobrazowano działanie takiego podejścia. Wektor  $(1, 0, 0, 1, 1, 1, 0, 0, 1, 0)$  to argument operatora. Kolorem zaznaczono losowe pozycje w wektorze, które zostaną zanegowane, w wyniku czego powstanie wektor wyjściowy  $(1, 1, 0, 1, 0, 1, 0, 0, 1, 1)$ .

Zmiany zachodzące w jednym osobniku nie powinny być zbyt drastyczne (tak, aby

Rys. 2.2. Działanie przykładowej realizacji operatora krzyżowania



był on zbliżony w reprezentacji do pierwotnego osobnika), ale też nie mogą być zbyt mało znaczące, ponieważ znacząco spowolniłoby to proces eksploracji, a co za tym idzie, obniżyłoby efektywność heurystyki. Gdyby przykładowy operator mutacji (z rysunku 2.3)) operował na wektorach o długości rzędu kilku tysięcy, to zamiana pojedynczego bitu byłaby zbyt mało znacząca, ponieważ rozwiązania przed i po jego zastosowaniu praktycznie by się od siebie nie różniły. Jeśli jednak operator zmieniałby około połowy bitów, to nowe rozwiązanie byłoby zbyt dalekie od pierwotnego, przez co heurystyka sprowadziłaby się do kompletnie losowego przeszukiwania przestrzeni rozwiązań.

W zależności od implementacji oba operatory opisane powyżej mogą być stosowane w różnej kolejności. Ponadto, od realizacji zależy to, czy mutacja jest stosowana jedynie na populacji z poprzedniego pokolenia, czy również na potomstwie. W tej pracy przyjmuje się, że krzyżowanie zostaje wykonane przed mutacją, a jego wyniki również mogą być przez nią modyfikowane. Dzięki temu próbkowanie przestrzeni rozwiązań jest gęstsze, niż gdybyśmy postępowali w inny sposób.

Te dwa kroki mają na celu losowe przeszukiwanie przestrzeni rozwiązań. Gdyby ograniczyć się jedynie do nich, to heurystyka nie dawałaby pożądanych wyników. W celu dojścia do optimum należy tę losowość jakoś ukierunkować. Jest to powód, dla którego na końcu każdego pokolenia do całej populacji (a więc osobników z początku pokolenia, potomstwa i osobników zmutowanych) stosuje się operator selekcji naturalnej. Jego zadaniem jest wybranie ze znanych rozwiązań tych, które są lepsze w sensie rozwiązywanego problemu. Zostaną one wykorzystane jako populacja używana w kolejnym pokoleniu. Intuicyjnie, operator ten pełni rolę negatywnych czynników środowiskowych, które sprawiają, że nie wszystkie osobniki danego gatunku przeżywają. Zgodnie z prawami rządzącymi naturą, większe prawdopodobieństwo przeżycia powinny mieć jednostki lepiej dopasowane do swojego środowiska, co w heurystyce przekłada się na

Rys. 2.3. Działanie przykładowej realizacji operatora mutacji



lepszą (mniejszą, lub większą, w zależności od rozwiązywanego zadania) funkcję oceny.

Najprostszym operatorem selekcji jest tzw. operator elitarny (nazywany też elitystycznym), którego działanie polega na zwróceniu określonej liczby bezwzględnie najlepszych osobników z dotychczasowej populacji. Mimo, że wydaje się to intuicyjne, to nie jest to rozwiązanie idealne. Praktyka pokazuje, że rozwiązania gorsze często mają cechy, które w dalszych pokoleniach, po kolejnych modyfikacjach, dają rozwiązania lepsze od dotychczasowych. Jest to powodem istnienia takich realizacji jak np. selekcja turniejowa, czy ruletkowa (opisane w rozdziale 5 w ramach opisu implementacji).

Tak sformułowany proces służy do efektywnego przeszukiwania przestrzeni rozwiązań, tymczasem zadanie optymalizacji ma na celu znalezienie jak najlepszego z nich. Oznacza to, że jedno z rozwiązań, które zostanie zbadane w trakcie działania heurystyki musi być zapamiętane i zwrócone jako wynik. Naiwnym podejściem jest analiza populacji po ostatnim pokoleniu i zwrócenie najlepszego z osobników. Jako, że operator selekcji nie gwarantuje tego, że w zbiorze wynikowym znajdzie się najlepszy osobnik ze zbioru wejściowego, to istnieje szansa, że najlepsze rozwiązanie z ostatniej populacji nie jest najlepszym rozwiązaniem znalezionym w trakcie działania heurystyki. Zamiast tego w trakcie symulacji zapamiętujemy globalnie najlepsze rozwiązanie na jakie trafiliśmy i właśnie je traktujemy jako rozwiązanie problemu optymalizacji. Zazwyczaj realizuje się to w ten sposób, że definiuje się zmienną przechowującą globalne optimum<sup>1</sup>, która początkowo ma wartość pustą. Po zakończeniu pierwszego pokolenia, ale przed zastosowaniem operatora selekcji, zapisuje się w niej najlepsze rozwiązanie w tym pokoleniu. W tym samym momencie w dalszych pokoleniach porównuje się ocenę obecnego globalnego optimum i najlepszego osobnika z danego pokolenia (optimum lokalnego). Jeśli optimum globalne jest gorsze niż lokalne, to zostaje nim zastąpione.

## 2.2. Formalny opis operatorów i parametrów

Niniejsza sekcja jest przeznaczona na formalny opis elementów algorytmu ewolucyjnego. Jak zostało zaznaczone w poprzedniej sekcji, sam schemat działania heurystyki zależy od implementacji, jednak pokazane tu definicje i sygnatury powinny być zgodne

1. W tym kontekście optima globalne i lokalne oznaczają najlepsze dotychczas znalezione rozwiązanie i najlepsze rozwiązanie w danej populacji.

z większością istniejących rozwiązań. Każde z opisywanych pojęć niesie ze sobą nie tylko znaczenie i zastosowanie wzorowane na przyrodzie, ale również ograniczenia nałożone na realizację danego elementu, również wynikające z natury. Wszystkie te aspekty zostaną podane i zapisane w formie, która ma zapobiec występowaniu nieścisłości.

W pierwszej podsekcji znajduje się zestaw konwencji związanych z diagramami, czcionkami, itd. używanymi w tej pracy. Normy te obowiązują w całym dokumencie, również w poprzednich sekcjach i rozdziałach.

Druga podsekcja opisuje pojęcie operatora, które jest często stosowane przy formalnych opisach elementu heurystyki. Dodatkowo, znajdziemy tam definicję operatora  $random(X)$ , który jest bardzo przydatny w dalszych opisach.

Kolejne pięć podsekcji skupia się już na konkretnych częściach heurystyki, które należy określić w celu jej wykorzystania.

### 2.2.1. Konwencje

W tabeli 2.1 zostały pokazane konwencje dotyczące znaczenia czcionek używane w tej pracy.

Na rysunku 2.4 zobrazowane zostały różne elementy schematów blokowych używane w tej pracy, opisane w tabeli 2.2.

Na rysunku 2.5 przedstawiono konwencje dotyczące rysowania wykresów przyjęte w tym dokumencie.

Ponadto, w sygnaturach operatorów i funkcji będą często wykorzystywane klasy zbiorów o konkretnym rozmiarze. Jako, że nie istnieje powszechnie przyjęta konwencja zapisu takiego bytu, w niniejszej pracy przyjęto, że zapis  $A^{\{n\}}$  oznacza klasę zbiorów *nelementowych*, w której każdy element należy do zbioru  $A$ . Zapis  $A^n$ , zgodnie ze standardową konwencją oznacza  $n$ -krotny iloczyn kartezjański zbioru  $A$ , czyli klasę wektorów o długości  $n$ , których składowe pochodzą ze zbioru  $A$ .

$$A^{\{n\}} \equiv \{a : a \subset A, |a| = n\} \quad (2.1)$$

$$A^{\{0\}} \equiv \emptyset \quad (2.2)$$

$$A^n \equiv \underbrace{A \times A \times \dots \times A}_n \quad (2.3)$$


$$A^0 \equiv \emptyset \quad (2.4)$$

$$A \times B \equiv \{(a, b) : a \in A, b \in B\} \quad (2.5)$$

**Tabela 2.1.** Konwencje dotyczące czcionek


<b>operator, n</b>	operatory i parametry heurystyki
<b>k</b>	parametry zależne od realizacji operatorów
<b>T, p</b>	zbiory i parametry pomocnicze
<b>S</b>	zbiory używane w definicjach
<b>R</b>	relacje
<b>N</b>	zbiory liczbowe

Rys. 2.4. Konwencje dotyczące elementów schematów blokowych

**Tabela 2.2.** Opis konwencji dotyczących elementów schematów blokowych

①	Symbol rozpoczęcia heurystyki.
②	Symbol rozpoczęcia heurystyki.
③	Symbol oznaczający ewaluację warunku C i kontynuację procesu zgodnie z jego wynikiem.
④	Symbol oznaczający wykonanie kroku opisanego przez S.
⑤	Symbol tożsamy z symbolem ④, jednak stosowany w opisie proponowanego podejścia dla zaznaczenia różnic ze standardowym schematem (używane w rozdziale 4).
⑥	Kombinacja symboli oznaczająca, że podczas wykonywania kroku S używany jest operator O.
⑦	Kombinacja symboli oznaczająca, że podczas wykonywania kroku S używany jest parametr P.
⑧	Symbol oznaczający, że dany schemat wyjaśnia szczegółowe działanie kroku D.
⑨	Symbol oznaczający rozpoczęcie lub zakończenie szczegółowo opisywanego kroku.
⑩	Symbol oznaczający wykonanie kolejnego symbolu dla każdego z elementów opisanych przez E.

Rys. 2.5. Konwencje dotyczące rysowania wykresów



### 2.2.2. Pojęcie operatora

W dalszych rozdziałach będziemy używać pojęcia „**operator**”, które jest zbliżone do pojęcia funkcji. Różnica między tymi dwoma terminami jest taka, że funkcja musi zawsze zwrócić tę samą wartość dla tego samego argumentu, podczas gdy takie ograniczenie nie musi być spełnione dla operatora. Innymi słowy pojęcie operatora pokrywa się z pojęciem funkcji z imperatywnych języków programowania, ale nie jest tożsame z funkcją w rozumieniu matematycznym.

Operator możemy też rozumieć jako zmienną losową opisaną rozkładem parametryzowanym jego argumentami.

Warto pamiętać, że każda funkcja (w rozumieniu matematycznym) jest operatorem.

Do operatorów możemy stosować niektóre pojęcia używane w stosunku do funkcji. Przez *dziedzinę* operatora rozumiemy przestrzeń dozwolonych argumentów operatora, a przez *przeciwdziedzinę* - zbiór wartości które może zwrócić. Aby uzyskać *wynik* operatora (czyli wartość przez niego zwracaną) *stosujemy* ten operator na *argumentach*.

Dodatkowo, operator możemy *parametryzować* aby uzyskać inny operator. Przez *parametry* rozumiemy argumenty które w ramach danego ciągu obliczeń są stałe. Przykładowo, operator sąsiedztwa o określonym rozmiarze  $d$  dla punktu  $(x, y)$ :

$$sasiedztwo((x, y), d) \in [x - d, x + d] \times [y - d, y + d]$$

możemy sparametryzować rozmiarem sąsiedztwa, aby uzyskać operator sąsiedztwa o konkretnym rozmiarze:

$$sasiedztwo_5(P) = sasiedztwo(P, 5)$$

*De facto* każdy operator opisywany w tej pracy może być parametryzowany. W kolejnych rozdziałach przyjęto konwencję według której definiując nowy operator zapisywana jest jego minimalna dziedzina, co nie oznacza, że podczas realizacji nie może on być parametryzowany. Analogicznie stwierdzenie, że operator powinien przyjmować



daną liczbę argumentów nie oznacza, że nie może on przyjmować ich więcej. Innymi słowy sygnatura postaci:

$$\text{operator} : D \rightarrow C$$

gdzie  $D$  oznacza dziedzinę, a  $C$  przeciwdziedzinę, jest równoważna z:

$$\text{operator} : D \times P \rightarrow C$$

gdzie  $P$  oznacza przestrzeń parametrów, zależnych od realizacji operatora.

Ponadto, w algorytmach znajdujących się w tej pracy używany jest operator  $\text{random}(X)$  opisany sygnaturą 1, zwracający losowy element zbioru  $X$  (z rozkładem równomiernym).

---

**Sygnatura 1** Operator  $\text{random}(S)$ 


---

$$\text{random} : A^{\{n\}} \rightarrow A \quad (2.6)$$

$$X \leftarrow \{x_0, x_1, \dots, x_{n-1}\} \quad (2.7)$$

$$\forall_{x_i, x_j \in X} P(\text{random}(X) = x_i) = P(\text{random}(X) = x_j) \quad (2.8)$$

$A$  to dowolny zbiór, a  $n$  jego rozmiar.

---

### 2.2.3. Osobnik, populacja i ocena

Podstawowym pojęciem w dziedzinie algorytmów ewolucyjnych jest osobnik, czyli rozwiązanie. Definiujemy go jako element przestrzeni rozwiązań, którą również musimy zdefiniować. Na te pojęcia nie ma nałożonych żadnych ograniczeń, jednak od ich realizacji zależy łatwość realizacji i efektywność działania pozostałych pojęć, opisanych w dalszych podsekcjach.

Ważniejszym pojęciem jest funkcja oceny. Wbrew nazwie nie musi być to funkcja w rozumieniu matematycznym, a operator (patrz: rozdział 2.2.2) <sup>2</sup>. Jego dziedziną powinna być przestrzeń możliwych osobników, a przeciwdziedziną dowolny zbiór na którym możemy określić relację porządku. Relacja ta odpowiada relacji bycia lepiej przystosowanym do środowiska w rzeczywistym procesie ewolucji.

---

**Sygnatura 2** Osobnik
 

---

$$\text{osobnik} \in \mathcal{S} \quad (2.9)$$

Zbiór  $\mathcal{S}$  to przestrzeń rozwiązań.

---

2. Stochastyczną funkcję oceny możemy zastosować na przykład w sytuacji, w której za pomocą algorytmu ewolucyjnego szukamy konfiguracji innej heurystyki. Osobnikiem w takiej sytuacji może być zestaw parametrów konfigurowanej heurystyki, a oceną - średnia jakość działania dla kilku uruchomień.

---

**Sygnatura 3** Funkcja oceny

---

$$\text{funkcjaOceny} : \mathcal{S} \rightarrow \mathcal{E} \quad (2.10)$$

$$\exists \mathbf{R}_{\prec} \subset \mathcal{E} \times \mathcal{E} \quad (2.11)$$

$$\mathbf{R}_{\triangleleft} \leftarrow \{(x, y) : (\text{funkcjaOceny}(x), \text{funkcjaOceny}(y)) \in \mathbf{R}_{\prec}\} \quad (2.12)$$

Zbiór  $\mathcal{E}$  to zbiór możliwych ocen osobnika, a  $\mathbf{R}_{\prec}$  to relacja porządku na nim określona. Ponadto określamy relację lepszego dopasowania  $\mathbf{R}_{\triangleleft}$ , porządkującą przestrzeń osobników według porządku określonego na ich ocenach.

---

**2.2.4. Operator mutacji**

Dziedziną tego operatora jest przestrzeń rozwiązań, a przeciwdziedziną - klasa melementowych podzbiorów przestrzeni rozwiązań. Oznacza to, że jednokrotne zastosowanie operatora mutacji daje w wyniku  $m$  osobników powstałych przez modyfikację osobnika pierwotnego. Każdy ze zwróconych osobników powinien być nieznacznie różny od argumentu operatora. Zazwyczaj przyjmuje się  $m = 1$ .

Z operatorem mutacji ściśle związany jest jeden z parametrów algorytmu ewolucyjnego - prawdopodobieństwo mutacji. Jest to wartość określająca prawdopodobieństwo zastosowania operatora mutacji do osobnika w danym pokoleniu. Jeśli wartość ta jest równa 0, to operator mutacji nie jest w ogóle używany, a jeśli jest równa 1, to operator zostanie zastosowany do każdego osobnika.

---

**Sygnatura 4** Operator mutacji

---

$$\text{opMutacji} : \mathcal{S} \rightarrow \mathcal{S}^{\{m\}} \quad (2.13)$$

$$\text{prawdMutacji} \in (0, 1) \quad (2.14)$$

$m$  to liczba zwracanych wyników mutacji.

---

**2.2.5. Operator krzyżowania**

Dziedziną tego operatora jest klasa celementowych podzbiorów przestrzeni rozwiązań, a przeciwdziedziną - klasa celementowych podzbiorów tej przestrzeni. Oznacza to, że operator ten przyjmuje  $\bar{c}$  osobników (nazywanych *rodzicami*) jako argument, a zwraca  $\underline{c}$  osobników (nazywanych *potomstwem*). Zazwyczaj przyjmuje się  $\bar{c} = 2$  i  $\underline{c} \in \{1, 2\}$ . Zwracane osobniki powinny być podobne (w takim sensie, że mają podobną reprezentację) do osobników wejściowych (argumentów operatora).

Z operatorem krzyżowania ściśle związany jest jeden z parametrów algorytmu ewolucyjnego - prawdopodobieństwo krzyżowania. Jest to wartość określająca prawdopodobieństwo zastosowania operatora krzyżowania do osobnika w danym pokoleniu. Jeśli wartość ta jest równa 0, to operator krzyżowania nie jest w ogóle używany, a jeśli jest równa 1, to operator zostanie zastosowany do każdego osobnika.

**Sygnatura 5** Operator krzyżowania

$$\text{opKryzowania} : \mathcal{S}^{\{\bar{c}\}} \rightarrow \mathcal{S}^{\{\underline{c}\}} \quad (2.15)$$

$$\text{prawdKryzowania} \in \langle 0, 1 \rangle \quad (2.16)$$

$\bar{c}$  to liczba rodziców, a  $\underline{c}$  to liczba potomków.

**2.2.6. Operator selekcji**

Zadaniem operatora selekcji jest symulacja zjawiska przeżycia silniejszych (czyli lepiej dopasowanych) osobników. Jest on stosowany pod koniec każdego pokolenia w celu usunięcia z niej osobników gorzej dopasowanych, poprzez wykorzystanie populacji wyjściowej jako używanej w kolejnym pokoleniu. Zmniejsza on różnorodność genetyczną w obrębie populacji, co w ogólności jest negatywnym efektem, ponieważ zahamowuje proces eksplorację przestrzeni rozwiązań. Operator mutacji powinien eksplorować ją na tyle efektywnie, żeby operator selekcji odrzucał mało obiecujące kierunki eksploracji zamiast całkiem zatrzymywać jej proces.

Dziedziną tego operatora jest klasa *pelementowych* pozdbiorów przestrzeni rozwiązań, co oznacza, że przyjmuje on populację  $p$  osobników. Wartość  $p$  to ilość osobników w populacji pod koniec danej generacji, więc można ją przybliżać za pomocą równań z linii 2.19-2.21 sygnatury 6, ponieważ w populacji znajdują się osobniki z populacji początkowej tego pokolenia oraz wyniki operatorów mutacji i krzyżowania.

Przeciwdziedziną operatora selekcji jest **rozmiarPopulacji** krotny iloczyn kartezyński przestrzeni rozwiązań, co oznacza, że wynikiem działania operatora powinien być zbiór **rozmiarPopulacji** osobników. Wartość **rozmiarPopulacji** to parametr całej heurystyki, określająca jak liczna powinna być populacja na początku każdego pokolenia. Im większą wartość przyjmuje ten parametr, tym lepsze przeszukiwanie przestrzeni rozwiązań, ale też tym dłużej trwa sama heurystyka (ponieważ trzeba ewaluować więcej osobników i do większej liczby z nich zastosować operatory genetyczne).

Dodatkowo na operator nakłada się wymóg opisany w liniach 2.22-2.25 sygnatury 6. Mówią one o tym, że prawdopodobieństwo tego, że osobnik z populacji wejściowej znajdzie się w populacji wyjściowej powinno być tym większe im lepiej dopasowany jest osobnik. Ma to symulować zasadę przetrwania osobników najlepiej przystosowanych do środowiska.

**2.2.7. Warunek stopu**

Warunek stopu, nazywany też warunkiem zatrzymania lub przerwania to pojęcie określające warunek zakończenia heurystyki. Jest to odpowiedź na pytanie „kiedy należy przestać przetwarzanie kolejnych pokoleń?”. Często stosuje się takie kryteria jak przekroczenie jakiejś arbitralnej liczby pokoleń, lub zaobserwowanie tzw. stagnacji. Zjawisko takie polega na znacznym zmniejszeniu różnorodności ocen w populacji, co oznacza, że znaleźliśmy optimum lokalne. Jeśli wariancja ocen przez kilka pokoleń się nie zmienia (lub zmienia, ale nie znacząco), to można uznać, że operatory genetyczne nie pozwolą na wyjście z tego optimum i przerwać działanie heurystyki. Warunek zatrzymania możemy traktować jako dodatkowy operator, jednak trudno jest określić jego jednoznaczną sygnaturę, ze względu na dowolność realizacji. W sygnaturze 7 przed-

**Sygnatura 6** Operator selekcji

$$\text{opSelekcji} : \mathcal{S}^{\{p\}} \rightarrow \mathcal{S}^{\{\text{rozmiarPopulacji}\}} \quad (2.17)$$

$$\text{rozmiarPopulacji} \in \mathbb{N}_+ \quad (2.18)$$

$$p \approx (1 + \text{prawdMutacji} \times m \quad (2.19)$$

$$+ \text{prawdKrzyzowania} \times \underline{c}) \quad (2.20)$$

$$\times \text{rozmiarPopulacji} \quad (2.21)$$

$$T \leftarrow \{t_0, t_1, \dots, t_{\text{rozmiarPopulacji}-1}\} \quad (2.22)$$

$$s \in \text{opSelekcji}(T) \Rightarrow s \in T \quad (2.23)$$

$$P(i) \leftarrow P(t_i \in \text{opSelekcji}(T)) \quad (2.24)$$

$$P(i) < P(j) \Leftrightarrow (t_i, t_j) \in \mathbf{R}_{\triangleleft} \quad (2.25)$$

stawiono ogólny zapis operatora (z dowolną dziedziną, linia 2.26) i sygnaturę jego przykładowej realizacji (opartej o stałą liczbę pokoleń, linie 2.27-2.28).

**Sygnatura 7** Warunek zatrzymania i jego przykładowa realizacja

$$\text{warunekStopu} : \dots \rightarrow \{0, 1\} \quad (2.26)$$

$$\text{warunekStopu} : \mathbb{N} \rightarrow \{0, 1\} \quad (2.27)$$

$$\text{warunekStopu}(g) = 1 \Leftrightarrow g \leq \bar{g} \quad (2.28)$$

Zwrócenie wartości 1 oznacza, że należy zakończyć działanie heurystyki, a 0 - sytuację odwrotną.

Wartość  $g$  oznacza numer obecnego pokolenia (zaczynając od 1), a  $\bar{g}$  - maksymalną dopuszczalną liczbę pokoleń w ramach jednego przebiegu algorytmu ewolucyjnego.

## 2.3. Szczegóły działania heurystyki

Ogólny schemat działania algorytmu ewolucyjnego został przedstawiony w sekcji 2.1. Kolejne kroki przedstawionego tam diagramu zostaną opisane ze szczegółami w kolejnych akapitach.

Cały proces rozpoczyna się od inicjalizacji populacji przy pomocy losowych osobników. Następnie, póki warunek zatrzymania nie jest spełniony, powtarzane jest kilka kroków wykonywanych w ramach jednego pokolenia. Są to kolejno: krzyżowanie, mutacja i selekcja naturalna.

Algorytm 2.1 opisuje szczegóły kroku "Wykonaj krzyżowanie". Krok ten rozpoczyna się od inicjalizacji zmiennej *noweOsobniki* na pusty zbiór (w linii 1), który w linii 9. zostanie dołączony do ogólnej populacji. Dla każdego osobnika w populacji (linia 2) sprawdzane jest, czy należy wykonać krzyżowanie z jego udziałem (linia 3). Jeżeli tak, to losowo dobierany jest jego partner (linia 4), a następnie na tak określonej parze

**Algorytm 2.1** Szczegółowy schemat działania kroku "Wykonaj krzyżowanie"

---

**Dostępne zmienne:**  
*populacja*  $\triangleright$  Obecna populacja, tj. zbiór osobników

**Parametry:**  
*prawdKrzyzowania*  $\triangleright$  Prawdopodobieństwo krzyżowania  
*opKrzyzowania*  $\triangleright$  Operator krzyżowania

```

0: procedure WYKONAJKRZYZOWANIE
1:   var noweOsobniki  $\leftarrow \emptyset$ 
2:   for all osobnik  $\in$  populacja do
3:     if  $\text{random}([0, 1]) \leq \text{prawdKrzyzowania}/2$  then
4:       var partner  $\leftarrow \text{random}(\text{populacja} \setminus \{\text{osobnik}\})$ 
5:       var potomek  $\leftarrow \text{opKrzyzowania}(\{\text{osobnik}, \text{partner}\})$ 
6:       noweOsobniki  $\leftarrow \text{noweOsobniki} \cup \{\text{potomek}\}$ 
7:     end if
8:   end for
9:   populacja  $\leftarrow \text{populacja} \cup \text{noweOsobniki}$ 
10: end procedure

```

---

osobników stosowany jest operator krzyżowania (linia 5), którego wynik jest dołączany do zbioru *noweOsobniki* (linia 6). Schemat ten przewiduje, że operator krzyżowania przyjmuje 2 osobniki jako argument (tzn.  $\bar{c} = 2$ , patrz: rozdział 2.2.5), przez co wartość, z którą porównujemy losowo wybraną liczbę z przedziału  $\langle 0, 1 \rangle$  to  $\text{prawdKrzyzowania}/2$ . W ogólności, dla dowolnego  $\bar{c}$  wartość ta wynosi  $\text{prawdKrzyzowania}/\bar{c}$ , a zamiast jednego partnera należy wybrać ich  $\bar{c} - 1$ .

**Algorytm 2.2** Szczegółowy schemat działania kroku "Wykonaj mutację"

---

**Dostępne zmienne:**  
*populacja*  $\triangleright$  Obecna populacja, tj. zbiór osobników

**Parametry:**  
*prawdMutacji*  $\triangleright$  Prawdopodobieństwo mutacji  
*opMutacji*  $\triangleright$  Operator mutacji

```

0: procedure WYKONAJMUTACJE
1:   var noweOsobniki  $\leftarrow \emptyset$ 
2:   for all osobnik  $\in$  populacja do
3:     if  $\text{random}([0, 1]) \leq \text{prawdMutacji}$  then
4:       var mutant  $\leftarrow \text{opMutacji}(\text{osobnik})$ 
5:       noweOsobniki  $\leftarrow \text{noweOsobniki} \cup \{\text{mutant}\}$ 
6:     end if
7:   end for
8:   populacja  $\leftarrow \text{populacja} \cup \text{noweOsobniki}$ 
9: end procedure

```

---

Algorytm 2.2 opisuje szczegóły kroku "Wykonaj mutację". Krok rozpoczyna się od inicjalizacji zmiennej *noweOsobniki* na pusty zbiór (w linii 1), który w linii 8 zostanie dołączony do ogólnej populacji. Dla każdego osobnika w populacji (linia 2) sprawdzane jest, czy należy wykonać na nim mutację (linia 3), a jeśli tak, to stosowany jest do niego

operator mutacji (linia 4), którego wynik zostaje dołączony do zbioru *noweOsobniki* (linia 5).

---

**Algorytm 2.3** Szczegółowy schemat działania kroku "Dokonaj selekcji naturalnej"
 

---

**Dostępne zmienne:**

*populacja*                                      ▷ Obecna populacja, tj. zbiór osobników

**Parametry:**

*rozmiarPopulacji*                                      ▷ Rozmiar populacji

*opSelekcji*    ▷ Operator selekcji

0: **procedure** DOKONAJSELEKCJINATURALNEJ

1:     *populacja*  $\leftarrow$  *opSelekcji*<sub>*rozmiarPopulacji*</sub>(*populacja*)

2: **end procedure**

---

Algorytm 2.3 opisuje szczegóły kroku "Dokonaj selekcji naturalnej", który *de facto* sprowadza się do zastąpienia dotychczasowej populacji wynikiem zastosowania operatora selekcji na niej (linia 1).

## 2.4. Analiza jakości działania

Algorytmy ewolucyjne to rodzina losowych, iteracyjnych heurystyk populacyjnych. Określenie „losowych” oznacza, że każde uruchomienie procesu optymalizacji może zwrócić inny wynik. Co za tym idzie, ocena działania heurystyki dla danego zestawu parametrów jest trudna i wymaga wielokrotnego zebrania wyników. W następnych podsekcjach opisane zostaną sposoby analizy jakości działania pojedynczego przebiegu heurystyki, jak i wielu przebiegów o tych samych parametrach.

### 2.4.1. Analiza jednego przebiegu heurystyki

Jak było wspomniane wyżej, algorytmy ewolucyjne to iteracyjne heurystyki populacyjne. Oznacza to, że w ramach jednego procesu optymalizacji wielokrotnie powtarzamy pewien krok (stąd określenie „iteracyjne”) w którym badamy wiele rozwiązań (stąd określenie „populacyjne”).

Aby ocenić pojedynczy przebieg, możemy analizować pewne statystyki oceny w skali populacji na przestrzeni wielu pokoleń.

Podstawowe statystyki używane w tym celu, to m.in.:

- najlepsza i najgorsza ocena osobnika z populacji,
- średnia i odchylenie standardowe (lub wariancja <sup>3</sup>) oceny osobników w populacji,
- mediana i kwantyle oceny osobników w populacji.

Wartości te można wygodnie zobrazować na wykresie pudełkowym, na osi odciętych umieszczając numery pokoleń, a na osi rzędnych - wartości odpowiednich statystyk. Takie zobrazowanie przebiegu heurystyki pozwala na wyciągnięcie wniosków i stosowne dopasowanie parametrów heurystyki (np. jeśli w problemie minimalizacji wszystkie


---

3. Często wariancji używa się do automatyzacji oceny, ponieważ obliczenie jej nie wymaga czasochłonnego pierwiastkowania. Znając wariancję w dowolnym momencie możemy obliczyć odchylenie standardowe, np. w celu prezentacji oceny.

wartości stopniowo maleją, to być może warto zwiększyć rozmiar populacji lub zmienić kryterium zatrzymania, aby cały proces trwał dłużej, ponieważ taka obserwacja wskazuje na efektywne działanie heurystyki).

W tej pracy do analizy wykorzystano tylko 4 z wyżej wymienionych statystyk: średnią, wariancję<sup>4</sup>, minimum i maksimum. Są one w pełni wystarczające do analizy porównawczej między uruchomieniami.


Rys. 2.6. Przykładowy wykres przebiegu



Na rysunku 2.6 przedstawiony jest przykładowy wykres statystyk populacji na przestrzeni wielu pokoleń. Wykresy takie, nazywane w skrócie *wykresami przebiegów*, będą wykorzystywane w tej pracy do analizy pojedynczych uruchomień heurystyki.


4. Zdecydowano się na wykorzystanie wariancji zamiast odchylenia standardowego ponieważ wartości odchylenia okazały się być zbyt małe, aby były dostrzegalne na wykresach.

Rys. 2.7. Wykres przebiegu, w którym globalne optimum nie znajduje się w ostatniej populacji



Na rysunku 2.7 przedstawiony jest wykres przebiegu na którym możemy zaobserwować sytuację opisaną na końcu rozdziału 2.1, tzn. taką, w której optimum globalne jest znalezione w innym pokoleniu niż ostatnie.

Rys. 2.8. Wykres przebiegu w którym obserwujemy stagnację



Na rysunku 2.8 przedstawiono sytuację, w której obserwujemy tzw. stagnację (wspominaną już w rozdziale 2.2.7). Możemy zaobserwować, że od pewnego momentu (około sześćdziesiątej generacji) kolejne pokolenia nie przynoszą znaczącej zmiany wyniku, co mogłoby być powodem do przerywania działania heurystyki.



### 2.4.2. Analiza wielu przebiegów heurystyki

Jak zostało wspomniane na początku tej sekcji, algorytmy ewolucyjne to heurystyki losowe, przez co za każdym uruchomieniem zwracają różne wartości. Aby ocenić wyniki procesu optymalizacji dla różnych zestawów parametrów należy kilkakrotnie powtórzyć proces i porównywać statystyki wyników. Jeśli jesteśmy w trakcie dostrajania heurystyki (czyli dobierania najlepszych parametrów), to taką statystyką może być najlepszy wynik z kilku powtórzeń, jednak jeśli chcemy przeprowadzić miarodajne badania, to najprostszym podejściem dającym wgląd w jakość działania jest obliczenie średniej i wariancji (lub odchylenia standardowego, patrz: przypis 3) wyników wielu przebiegów dla różnych konfiguracji i porównanie ich testem statystycznym, takim jak np. test t-studenta.



## Rozdział 3

# Przegląd literatury



## Rozdział 4

# Proponowane rozwiązania

Dotychczasowe implementacje algorytmów ewolucyjnych zazwyczaj (choć nie zawsze [7], [9]) pomijały ważny aspekt procesu ewolucji, który w przyrodzie okazuje się mieć duży wpływ na dopasowywanie się gatunków do środowiska - podział gatunku na płcie. W rzeczywistości większa część istniejących gatunków, zaczynając od dość prostych (jak owady, czy rośliny), a kończąc na złożonych (takich jak ssaki), do rozmnażania potrzebują dwóch rodziców różniących się konkretnym chromosomem. Różnica ta jest powodem istnienia całego zespołu cech, które pozwalają podzielić osobniki na żeńskie i męskie, a w ogólności na osobniki różnych płci. Mimo, że nie jest to spotykane w naturze, to w ramach eksperymentu myślowego można założyć dowolną liczbę płci, a nie tylko dwie.

W tym rozdziale zostanie zaproponowana heurystyka, która uwzględnia aspekt płci jako integralną część swojego działania, a nie (jak w istniejących rozwiązaniach) jako modyfikację powszechnie używanej metody.

Przy opisywaniu operatorów wprowadzanych w tym rozdziale, używana będzie funkcja  $plec(osobnik)$ , przypisująca osobnikowi jego płeć. Oznacza to, że przestrzeń rozwiązań musi zostać poszerzona o dodatkowy wymiar, jakim jest właśnie ta cecha. Jedyne wymaganie nałożone na jej dziedzinę to to, żeby była skończonym, niepustym zbiorem.

---

**Sygnatura 8** Funkcja  $plec(osobnik)$

---

$$plec : \mathcal{S} \rightarrow \mathcal{G} \tag{4.1}$$

---

### 4.1. Heurystyka DSEA

Jak zostało pokazane w rozdziale 3, istnieją rozwiązania które nie ignorują podziału populacji na płcie. Aby skutecznie je porównać i zaproponować nowe podejście, zdefiniowano schemat działania heurystyki, opisany schematem blokowym znajdującym się na rysunku 4.1. Ujmuje on wyżej opisany aspekt biologii organizmów w ramach nowego operatora selekcji. W dalszej części pracy tak zdefiniowaną heurystykę nazywać

---

**Sygnatura 9** Osobnik w kontekście DSEA
 

---

$$\mathcal{S}_{DSEA} = \mathcal{S}_{EA} \times \mathcal{G} \quad (4.2)$$

$$\mathcal{G} \neq \emptyset \quad (4.3)$$

$$|\mathcal{G}| < \infty \quad (4.4)$$

$\mathcal{G}$  to zbiór możliwych płci.

W niniejszej pracy przyjęto istnienie co najwyżej 2 płci, ze zbiorem płci określonym jako  $\mathcal{G} = \{\odot\}$  lub  $\mathcal{G} = \{\varnothing, \sigma\}$ .

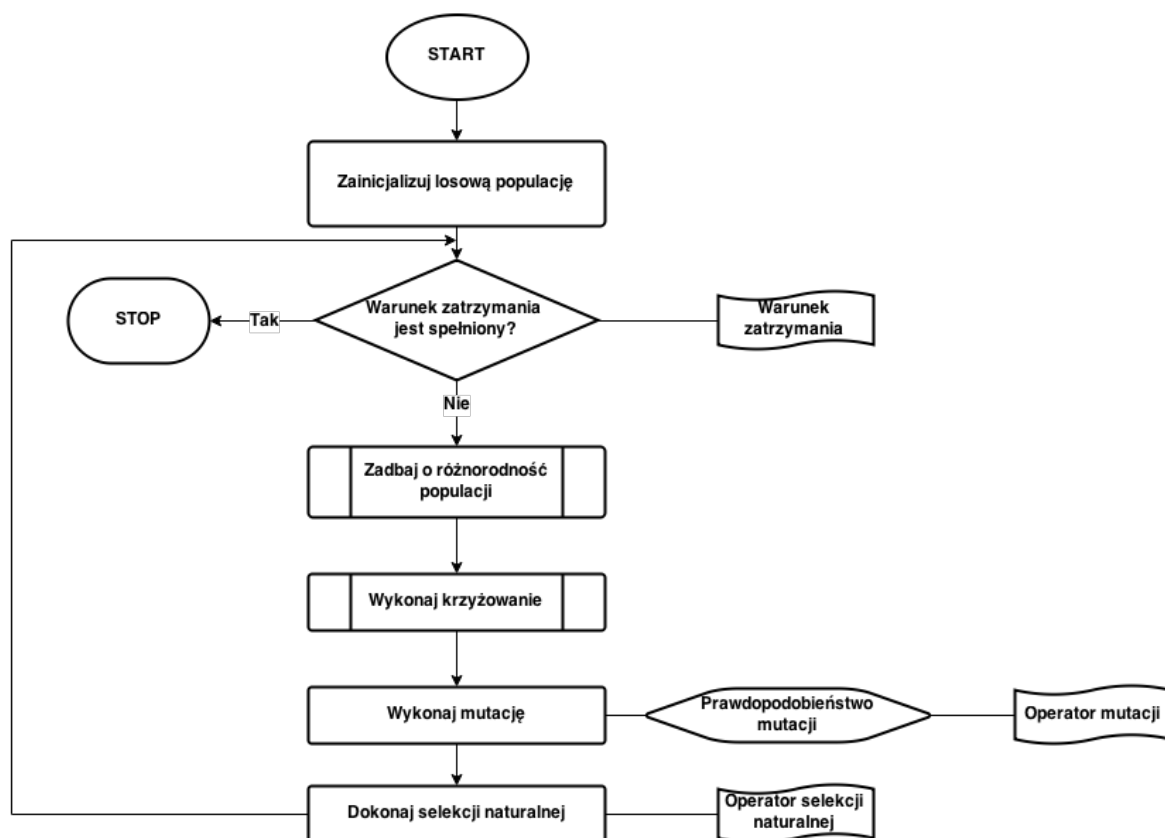
---

będziemy **algorytmem ewolucyjnym o podwójnej selekcji** (ang. *double selection evolutionary algorithm*) i odnosić się do niej przy pomocy skrótu **DSEA**, będącego akronimem nazwy angielskiej.

#### 4.1.1. Działanie

Na rysunku 4.1 przedstawiono schemat działania heurystyki DSEA w postaci schematu blokowego.

Rys. 4.1. Schemat działania heurystyki DSEA

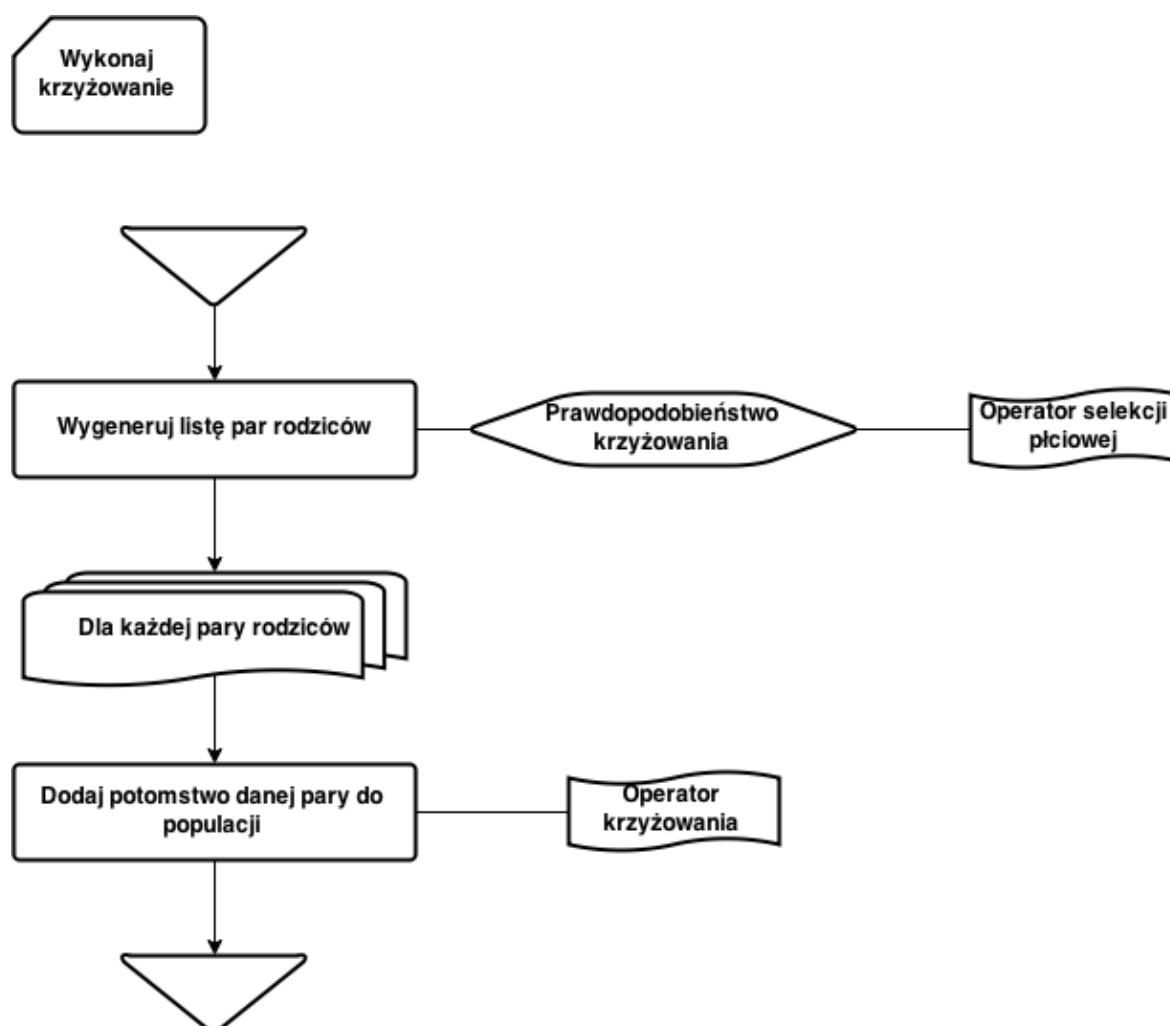


W większej części diagram zgadza się z diagramem 2.1 przedstawionym w sekcji 2.1. Istotne różnice między diagramami to zmiana działania kroku "Wykonaj krzyżowanie

oraz dodanie nowego kroku *Źadbaj o różnorodność populacji* zaraz przed nim. Zostały one zdefiniowane w paragrafach kolejno 4.1.1 i 4.3. Ponadto, zmieniła się nazwa operatora używanego w kroku *"Dokonaj selekcji naturalnej"*, co zostanie opisane w podsekcji 4.1.2.

### Krok „Wykonaj krzyżowanie”

Rys. 4.2. Szczegóły działania kroku „Wykonaj krzyżowanie”



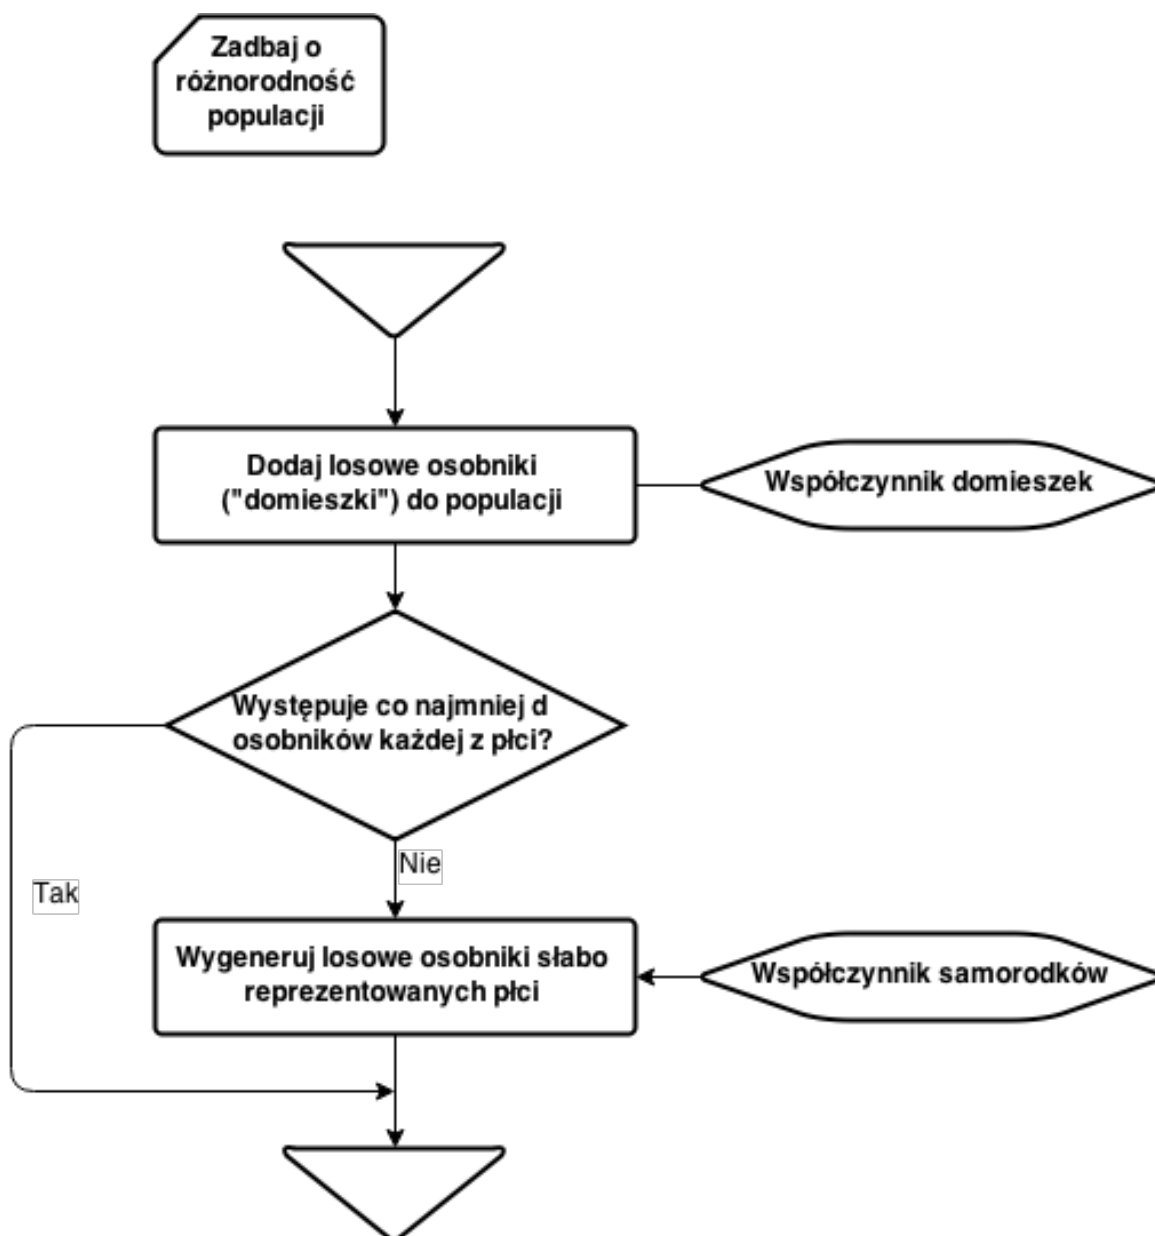
Na rysunku 4.2 znajduje się diagram przedstawiający krok *"Wykonaj krzyżowanie"* jako sekwencję mniejszych kroków. Za pomocą operatora selekcji płciowej<sup>1</sup> generowana jest lista par rodziców. Następnie, dla każdej z nich wykonuje się krzyżowanie, traktując oba osobniki z pary jako argumenty operatora krzyżowania, a jego wynik dołączając do populacji. W przeciwieństwie do realizacji opisanej w sekcji 2.3 przy pomocy algorytmu 2.1 wyniki operatora krzyżowania nie są dołączane do osobnego

1. W podsekcji 4.1.3 opisane zostanie znaczenie i sygnatura tego operatora, wyjaśnione jest uproszczenie polegające na zwracaniu par rodziców oraz różnica w interpretacji parametru `prawdKrzyzowania`.

zbioru, a od razu do całości populacji. Dzieje się tak, ponieważ zadanie wyboru rodziców jest oddelegowane do operatora, który zawsze zostanie użyty przed operatorem krzyżowania.

### Krok „Zadbaj o różnorodność populacji”

Rys. 4.3. Szczegóły działania kroku „Zadbaj o różnorodność populacji”



Wprowadzenie podziału populacji na płcie powinno skutkować odmiennym traktowaniem osobników w zależności od tej cechy. Co za tym idzie, obie podgrupy powinny różnić się tym bardziej, im więcej generacji zostało przeprowadzonych. Efekt taki ma zarówno wady, jak i zalety. Dzięki niemu potomstwo (czyli wynik operatora krzyżowania) w danej populacji powinno również zachować większą różnorodność. Negatywną



stroną tego zjawiska jest fakt, że operator selekcji naturalnej, który nie powinien brać pod uwagę płci, może zaburzyć stosunek liczności osobników danych płci względem siebie. W skrajnych sytuacjach może dojść do tego, że w całej populacji zabraknie osobników którejś z płci, co uniemożliwi dalsze działanie heurystyki (ponieważ niemożliwe byłoby zastosowanie operatora krzyżowania). Ponadto, im dysproporcje między różnymi płciami będą większe, tym mniejsza będzie różnorodność całej populacji, co szybko prowadzi do stagnacji.

Na rysunku 4.3 przedstawiono krok mający ograniczyć negatywne efekty podziału na płcie, opisane wyżej.

W pierwszej jego części do populacji dodajemy tzw. „domieszki” (ang. *mixins*), czyli losowe osobniki (tworzone w ten sam sposób co populacja początkowa). Ma to na celu regularne uzupełnianie puli genów obecnych w populacji, na wypadek gdyby geny odpowiedzialne za pozytywną cechę zanikły z powodu losowości operatora selekcji naturalnej lub płciowej. Ilość domieszek jest kontrolowana przez współczynnik domieszek (`wspDomieszek`), będący stosunkiem pożądanej ilości nowych osobników do wartości `rozmiarPopulacji`.

Druga część kroku ma zapobiec sytuacjom, w których któraś płć nie występuje w populacji, lub jest zbyt słabo reprezentowana. Jeśli liczność którejś z płci w populacji spadnie poniżej arbitralnie dobranej liczby  $d$ , to do populacji dołączane jest  $\lceil \text{wspSamorodków} \times \text{rozmiarPopulacji} \rceil$  (lub  $d$ , jeśli  $d$  jest większe) losowych osobników tej płci<sup>2</sup>. W praktyce, w ramach tej pracy użyto arbitralnie dobranych wartości  $d = 5$  i `wspSamorodków` = 0.05.

#### 4.1.2. Operator selekcji naturalnej

Heurystyka DSEA, jak nazwa wskazuje, korzysta z dwóch operatorów selekcji, które należy różróżnić. Z tego powodu dotychczasowy operator selekcji zmienił nazwę na **operator selekcji naturalnej**. Zachowuje on to samo znaczenie i zastosowanie, opisane w rozdziale 2.2.6.

Dodatkowo, wymaga się, aby prawdopodobieństwo znalezienia się osobnika w zbiorze zwracany przez ten operator było niezależne od płci osobnika. Zostało to zapisane w linii 4.14 sygnatury 10, korzystając z twierdzenia zgodnie z którym prawdopodobieństwo łączne dwóch zdarzeń jest równe iloczynowi ich prawdopodobieństw wtedy i tylko wtedy, gdy są to zdarzenia niezależne.

Standardowo korzysta się z operatorów selekcji naturalnej które odpowiednią ilość razy powtarzają wybór pojedynczego osobnika (bez powtórzeń) z populacji wejściowej, zbierając w ten sposób populację wyjściową. O ile sam sposób wyboru różni się między realizacjami operatora, to kolejne osobniki dołączane do populacji wyjściowej są zazwyczaj wybierane przy pomocy tego samego podejścia, które dalej będzie nazywane operatorem wyboru. Został on zdefiniowany w sygnaturze 11. Rzecz jasna istnieją realizacje, które korzystają z wielu operatorów wyboru, ale nie są one tematem tej pracy i nie będą w niej poruszane.

Realizacje operatorów wyboru nazywamy zgodnie z nazwami operatorów selekcji które z nich korzystają. Przykładowo, turniejowy operator selekcji korzysta z turniejo-

---

2. Alternatywnym rozwiązaniem mogłaby być zmiana płci losowych osobników pozostałych płci.

---

**Sygnatura 10** Operator selekcji naturalnej
 

---

$$\text{opSelNat} : \mathcal{S}^{\{p\}} \rightarrow \mathcal{S}^{\{\text{rozmiarPopulacji}\}} \quad (4.5)$$

$$\text{rozmiarPopulacji} \in \mathbb{N}_+ \quad (4.6)$$

$$p \approx (1 + \text{prawdMutacji} \times m \quad (4.7)$$

$$+ \text{prawdKrzyzowania} \times c) \quad (4.8)$$

$$\times \text{rozmiarPopulacji} \quad (4.9)$$

$$T \leftarrow \{t_0, t_1, \dots, t_{\text{rozmiarPopulacji}-1}\} \quad (4.10)$$

$$s \in \text{opSelNat}(T) \Leftrightarrow \exists_{t \in T} t \equiv s \quad (4.11)$$

$$P(i) \leftarrow P(t_i \in \text{opSelNat}(T)) \quad (4.12)$$

$$\forall_{i=0 \dots \text{rozmiarPopulacji}-1} P(i) < P(j) \Leftrightarrow (t_i, t_j) \in \mathbf{R}_{\triangleleft} \quad (4.13)$$

$$\forall_{i=0 \dots \text{rozmiarPopulacji}-1, g \in \mathcal{G}} P(i \wedge \text{plec}(t) = g) = P(i) \times P(\text{plec}(t_i) = g) \quad (4.14)$$


---

---

**Sygnatura 11** Operator wyboru
 

---

$$\text{opWyboru} : \mathcal{S}^{\{p\}} \rightarrow \mathcal{S} \quad (4.15)$$


---

wego operatora wyboru. Operatory wykorzystane w tej pracy zostały opisane w podsekcji 5.2.1 przy okazji opisu implementacji wykorzystanej do badań.

Warto zauważyć, że wcześniej zdefiniowany (sygnatura 1 w rozdziale 2) operator  $\text{random}(X)$  może być traktowany jako operator wyboru. Nie nadaje się on do zastosowań mających na celu poprawę wyników heurystyki, jednak korzystając z niego możemy opisać istniejące podejścia w modelu DSEA (patrz: podsekcja 4.1.4).

Wydzielenie abstrakcji wyboru jednego rozwiązania pozwala na zapisanie uogólnionego schematu działania większości popularnie stosowanych operatorów selekcji. Jest on opisany w algorytmie 4.1.

Działanie takiego operatora zaczyna się od inicjalizacji zmiennej *wynik*, zwracanej jako rezultat (linia 5). Początkowa jej wartość to zbiór pusty (linia 1), jednak w kolejnym kroku rozpoczyna się pętla, powtarzana tak długo, aż zbiór ten będzie miał odpowiedni rozmiar (linia 2). W ciele tej pętli za pomocą operatora wyboru *opWyboru* dokonuje się selekcji jednego nie wybranego jeszcze rozwiązania i dołącza się je do zbioru *wynik* (linia 3).

#### 4.1.3. Operator selekcji płciowej

W przeciwieństwie do tego jak działają klasyczne algorytmy ewolucyjne, w przyrodzie fakt dobierania się osobników w pary w celu wydania potomstwa nie jest losowy. W zależności od gatunku i sytuacji środowiskowej przedstawiciele jednej lub obu płci muszą przekonać swoich przyszłych partnerów o tym, że mają cechy, które przekazane potomstwu dałyby mu większą szansę na przetrwanie. Sposoby na to są różne - samce różnych gatunków rywalizują o samice poprzez walkę, okrzyki i śpiew, taniec, itd. U innych gatunków to samice zabiegają o względy partnerów. Ponadto, różne gatunki

---

**Algorytm 4.1** Schemat działania operatora selekcji naturalnej korzystającego z operatora wyboru

---

**Wejście:**  
*populacja* ▷ Populacja wyjściowa

**Wyjście:**  
*wynik* ▷ Populacja wyjściowa

**Parametry:**  
*rozmiarPopulacji* ▷ Rozmiar populacji  
*opWyboru* ▷ Operator wyboru

```

0: operator opSelNat(populacja)
1:   var wynik  $\leftarrow \emptyset$ 
2:   while  $|wynik| < rozmiarPopulacji$  do
3:     wynik  $\leftarrow wynik \cup \{opWyboru(populacja \setminus wynik)\}$ 
4:   end while
5:   return wynik
6: end operator

```

---

stosują różne strategie wiązania się w pary. Niektóre z nich starają się krzyżować tak często jak to możliwe z możliwie dużą liczbą partnerów, co powoduje dużą liczbę potomstwa, z których „odsiewana” jest słabo przystosowana do środowiska większość. Inne wiążą się w pary na całe życie (jak np. niektóre gatunki ptaków), albo przynajmniej na jakiś czas, dłuższy niż jedno pokolenie.

Operator selekcji płciowej to nowy element schematu heurystyki, który ma symulować te zjawiska i strategie. W ogólności osobniki lepiej dopasowane do środowiska powinny mieć większą szansę na zostanie rodzicami niż te dopasowane gorzej. Zastosowanie tego operatora do populacji z poprzedniego pokolenia powinno zwrócić zestaw par osobników-rodziców, z których każda para zostanie dalej przekazana do operatora krzyżowania.

W naturze, podobnie jak w podejściach porównywanych w tej pracy, rodziców jest dwoje. W sztucznym środowisku symulacyjnym liczba ta może być w gruncie rzeczy dowolna. Oznacza to, że wspomniane wyżej pary rodziców mogą być zbiorami o dowolnym rozmiarze.

Dotychczasowe algorytmy ewolucyjne można traktować jako DSEA z losowym operatorem selekcji płciowej.

Zmienia się znaczenie prawdopodobieństwa krzyżowania. Nazwa tego parametru zostaje bez zmian, aby nie komplikować nazewnictwa, jednak sama wartość nie przekłada się na matematyczne prawdopodobieństwo tego, że losowy osobnik zostanie rodzicem. Zamiast tego może być rozumiana jako stosunek liczby zdarzeń krzyżowania w każdym pokoleniu do rozmiaru populacji. Jest to ściśle związane z liczbą potomków tworzonych w jednej generacji, jednak przez to, że krzyżowanie może skutkować utworzeniem więcej niż jednego potomka, nie należy rozumieć tego parametru jako stosunku liczby krzyżówek do rozmiaru populacji.

**Sygnatura 12** Operator selekcji płciowej

$$\text{opSelPłciowej} : \mathcal{S}^{\{\text{rozmiarPopulacji}\}} \rightarrow (\mathcal{S}^{\{\bar{c}\}})^{\{q\}} \quad (4.16)$$

$$q = \lceil \text{prawdKrzyzowania} \times \text{rozmiarPopulacji} \rceil \quad (4.17)$$

$$T \leftarrow \{t_0, t_1, \dots, t_{\text{rozmiarPopulacji}-1}\} \quad (4.18)$$

$$\exists_{P \in \text{opSelekcji}(T)} t \in P \Rightarrow t \in T \quad (4.19)$$

$\bar{c}$  to ilość osobników potrzebna do wykonania krzyżowania (patrz: sygnatura 5, rozdział 2.2.5).

Operator zwraca zbiór  $q$  zbiorów, z których każdy zawiera  $\bar{c}$  osobników.

**4.1.4. Realizacja wybranych operatorów selekcji płciowej**

W rozdziale 3 przedstawiono przegląd prac naukowych o tematyce zgodnej z tematem tej pracy, tj. z uwzględnianiem zjawiska płci w algorytmach ewolucyjnych. Spośród przedstawionych tam pozycji wybrano dwie, które prezentowały nieco odmienne podejścia do zagadnienia: GGA [7], które opierało się o wymuszenie różnych płci rodziców, wybierając ich losowo, oraz SexualGA [9], w którym nie wprowadzano rozróżnienia osobników na płcie, ale każdego z rodziców wybierano w inny sposób, tj. za pomocą innego operatora wyboru.

Oba te podejścia można opisać przy pomocy tego samego schematu, jednak odmiennie parametryzowanego dla każdej z tych metod. Jego działanie jest wyjaśnione w algorytmie 4.2.

Działanie operatora rozpoczyna się od deklaracji i inicjalizacji zmiennych pomocniczych. Zbiór *rodzice* początkowo jest pusty (linia 1). Dodatkowo, deklarujemy dwa zbiory przechowujące kandydatów na każdego z rodziców (linie 2-3). W zależności od parametru *plecMaZnaczenie* przechowują one albo całą populację (jeżeli zachodzi *plecMaZnaczenie* =  $\perp$ , czyli rodzice mogą być tej samej płci), albo odfiltrowane osobniki odpowiedniej płci (jeżeli *plecMaZnaczenie* =  $\top$ , czyli wymagane jest, aby rodzice byli różnych płci).

Następnie, póki nie zostanie wybrana odpowiednia liczba par rodziców (linia 4) powtarzany jest zestaw operacji określający kolejną z nich. Za pomocą operatora *opWyboru1* ze zbioru *kandydaci1* wybierany jest pierwszy rodzic (linia 5). Drugi z rodziców jest wybierany ze zbioru *kandydaci2* za pomocą operatora *opWyboru2* (linia 6), nie dopuszczając do sytuacji w której oboje rodziców byłoby tym samym osobnikiem (mogłoby się tak zdarzyć, jeżeli *plecMaZnaczenie* =  $\perp$ , więc oboje z nich byłoby wybieranych z całej populacji). Dwuelementowy zbiór tak wybranych rodziców jest dołączany do zbioru *rodzice*.

Kiedy określimy odpowiednio dużo par, zmienna *rodzice* jest zwracana jako wynik operatora (linia 9).

Tak określona realizacja powiela założenie tej pracy, zgodnie z którym płci jest co najwyżej 2 ( $|\mathcal{G}| \in \{1, 2\}$ ; jeżeli *plecMaZnaczenie* =  $\perp$  to liczność tego zbioru nie ma znaczenia, ponieważ funkcja *plec(s)* nie jest używana, w jednak w przeciwnej sytuacji musi ona wynosić 2), dodatkowo zakładając liczbę rodziców wymaganą przez operator krzyżowania  $\bar{c} = 2$ . Algorytm można dość łatwo uogólnić do postaci, w której liczby te są większe, pamiętając, że jeżeli *plecMaZnaczenie* =  $\top$ , to rodzice muszą

---

**Algorytm 4.2** Schemat działania wybranych operatorów selekcji płciowej

---

**Wejście:***populacja*

▷ Populacja wyjściowa

**Wyjście:***rodzice*

▷ Zbiór par rodziców

**Parametry:***opWyboru1*

▷ Operator wyboru pierwszego z rodziców

*opWyboru2*

▷ Operator wyboru drugiego z rodziców

*plecMaZnaczenie*▷ Wartość logiczna określająca, czy rodzice  
muszą różnić się płcią*prawdKrzyzowania*

▷ Prawdopodobieństwo krzyżowania

*rozmiarPopulacji*

▷ Ilość osobników na początku pokolenia

0: **operator** *opSelPlciowej*(*populacja*)1:   **var** *rodzice*  $\leftarrow \emptyset$ 2:   **var** *kandydaci1*  $\leftarrow \begin{cases} \{s : plec(s) = \text{♀}, s \in populacja\} & : plecMaZnaczenie = \top \\ populacja & : plecMaZnaczenie = \perp \end{cases}$ 3:   **var** *kandydaci2*  $\leftarrow \begin{cases} \{s : plec(s) = \text{♂}, s \in populacja\} & : plecMaZnaczenie = \top \\ populacja & : plecMaZnaczenie = \perp \end{cases}$ 4:   **while**  $|rodzice| < rozmiarPopulacji \times prawdKrzyzowania$  **do**5:     **var** *rodzic1*  $\leftarrow opWyboru1(kandydaci1)$ 6:     **var** *rodzic2*  $\leftarrow opWyboru2(kandydaci1 \setminus \{rodzic1\})$ 7:     *rodzice*  $\leftarrow rodzice \cup \{\{rodzic1, rodzic2\}\}$ 8:   **end while**9:   **return** *rodzice*10: **end operator**Symbole  $\top$  i  $\perp$  oznaczają kolejno prawdę i fałsz.

---

być różnych płci, więc rozmiar argumentu operatora krzyżowania musi być równy ich liczbie ( $\bar{c} = |\mathcal{G}|$ ).

### Standardowe algorytmy ewolucyjne

Jeżeli:

- użyto operatora selekcji płciowej opisanego powyżej, sparametryzowanego przy pomocy:
    - `plecMaZnaczenie` =  $\perp$ ,
    - `opWyboru1` = *random*,
    - `opWyboru2` = *random*,
  - użyto wybranego operatora selekcji naturalnej (`opSelNat`  $\neq$  *random*),
  - zignorowano liczbę płci ( $|\mathcal{G}| \in \mathbb{N}_+$ ), ponieważ `plecMaZnaczenie` =  $\perp$ ,
- to DSEA sprowadza się do standardowego algorytmu ewolucyjnego, w którym na prawdopodobieństwo wydania potomstwa ma wpływ jedynie operator selekcji naturalnej.

### GGA

GGA [7] to wariacja na temat algorytmu genetycznego (co oznacza, że jej autorzy wykorzystywali reprezentację osobnika przez wektor bitów), w której wyróżnia się cechę osobnika określającą jego płeć i wymaga, aby rodzice różnili się nią. Każdy z rodziców jest wybierany losowo. Można to zrealizować spełniając następujące warunki:

- użyto operatora selekcji płciowej opisanego powyżej, sparametryzowanego przy pomocy:
  - `plecMaZnaczenie` =  $\top$ ,
  - `opWyboru1` = *random*,
  - `opWyboru2` = *random*,
- użyto wybranego operatora selekcji naturalnej (`opSelNat`  $\neq$  *random*),
- liczba płci jest większa niż 1 ( $|\mathcal{G}| > 1$ ).

### SexualGA

SexualGA [9] to kolejna wariacja na temat algorytmu genetycznego. Autorzy nie wyróżniali w niej cechy określającej płeć osobnika, proponując inne podejście do tego zjawiska. Przedstawione rozwiązanie wykorzystywało operator selekcji do wybrania rodziców, a nie osobników przechodzących do kolejnego pokolenia, a każdy z nich był wybierany za pomocą innego operatora wyboru<sup>3</sup>. Miało to symulować różne zachowania samców i samic związane z wyborem partnera.

Jeżeli poniższe warunki będą spełnione, to DSEA sprowadza się do SexualGA:

- użyto operatora selekcji płciowej opisanego powyżej, sparametryzowanego przy pomocy:
  - `plecMaZnaczenie` =  $\perp$ ,
  - `opWyboru1`  $\neq$  *random*  $\vee$  `opWyboru2`  $\neq$  *random*,
- użyto losowego operatora selekcji naturalnej (`opSelNat` = *random*),
- zignorowano liczbę płci ( $|\mathcal{G}| \in \mathbb{N}_+$ ), ponieważ `plecMaZnaczenie` =  $\perp$ .

Podany wyżej warunek, mówiący o tym, że co najmniej jeden operator wyboru musi być różny od losowego (*random*) wynika z tego, że gdyby oba operatory działały losowo, to heurystyka polegałaby na kompletnie przypadkowym przeszukiwaniu przestrzeni

3. W oryginalnej pracy nie używano określenia „operator wyboru”, a „operator selekcji”.

rozwiązań. Według autorów najlepsze wyniki osiągnęto używając operatora losowego w połączeniu z innym, różnym od niego, jednak sytuacja w której użyto tego samego operatora dla obu płci jest warta zbadania.

## 4.2. Proponowany operator selekcji płciowej

U wielu gatunków występujących w przyrodzie (np. u większości płetwonogich, w tym morsów i fok [6]) występuje zjawisko formowania się haremów. Polega ono na tym, że tylko mała liczba osobników jednej z płci (zazwyczaj samców<sup>4</sup>, nazywanych dalej *osobnikami alfa*) przyczynia się do wydania na świat potomstwa. Oznacza to, że dostęp do grupy samic (nazywanej *haremem*) ma bardzo ograniczona grupa jednostek. Dzieje się tak, ponieważ osobniki alfa są w ogólności silniejsze od pozostałych i bronią dostępu do samic przed resztą samców. Zakaz ten nie zawsze jest przestrzegany. W momencie, w którym osobniki alfa są czymś zajęte, pewien odsetek osobników tej samej płci ma szansę na rozmnożenie się. Osobniki którym się to uda nazywane są *osobnikami beta*.

Mimo, że takie zjawisko w dużym stopniu ogranicza różnorodność genetyczną, to w naturze wydaje się przynosić pozytywne rezultaty. Z tego powodu zdecydowano się zbadać haremowe podejście do dobierania się w pary w celu rozmnażania. Zrealizowano to definiując realizację operatora selekcji płciowej, nazywaną operatorem haremowym, opisaną w algorytmie 4.3. Wymaga ona, aby w populacji występowały dokładnie 2 płcie ( $|\mathcal{G}| = 2$ ).

Działanie takiego operatora zależy od pięciu parametrów, poza parametrami samej heurystyki. Są to trzy operatory wyboru: `opWyboruAlfa` służący do wyboru osobników alfa, `opWyboruBeta` używany do wyboru osobników beta oraz `opWyboruPartnerów` wykorzystywany do wyboru partnerów dla osobników alfa i beta. Ponadto, wykorzystywane są dwa parametry liczbowe: `liczbaAlfa` określający liczbę osobników alfa wybieranych w pojedynczym pokoleniu i `wspBeta`, czyli współczynnik określający stosunek liczby par rodziców z których jeden jest osobnikiem beta do liczby wszystkich par rodziców

Działanie operatora zaczyna się od inicjalizacji zmiennej *rodzice* na pusty zbiór (linia 1) oraz rozdzielenia populacji na zbiory *kandydaci1* i *kandydaci2*, zawierające osobniki różnych płci (linie 2 - 3). Następnie obliczane są wartości *liczbaZbiorowRodzicow*, czyli całkowita liczba par rodziców zwracanych przez operator (linia 4), *liczbaBeta*, czyli liczba osobników beta biorących udział w rozmnażaniu (linia 5), oraz *perAlfa*, czyli liczba par rodziców przypadających na jednego osobnika alfa (linia 6).

Kolejnym krokiem jest wygenerowanie par rodziców zawierających osobnika alfa. `liczbaAlfa` razy powtarzane jest (w pętli w linii 7) wybranie kolejnego takiego osobnika *alfa* (w linii 8) i usunięcie go ze zbioru kandydatów danej płci (w linii ??). Dzięki temu żaden osobnik alfa nie zostanie wybrany dwukrotnie, ani nie pokryje się z którymś z osobników beta. Dla danego osobnika alfa wybierany jest *perAlfa* (w pętli w linii 10) partnerów *partner* (linia 11), a tak określone pary rodziców są dołączane do zbioru *rodzice* (w linii 12).

4. Mimo, że nie zawsze osobniki alfa są płci męskiej, to w dalszej części opisu będziemy zakładać, że tak właśnie jest, mimo, że to uproszczenie.

---

**Algorytm 4.3** Schemat działania operatora haremowego
 

---

**Wejście:***populacja*

▷ Populacja wyjściowa

**Wyjście:***rodzice*

▷ Zbiór par rodziców

**Parametry:***liczbaAlfa*

▷ Liczba osobników alfa

*wspBeta* ▷ Stosunek liczby par rodziców zawierających osobnika alfa do liczby wszystkich par*opWyboruAlfa*

▷ Operator wyboru osobników alfa

*opWyboruBeta*

▷ Operator wyboru osobników beta

*opWyboruPartnerow* ▷ Operator wyboru partnerów przeciwnej płci*prawdKrzyzowania*

▷ Prawdopodobieństwo krzyżowania

*rozmiarPopulacji* ▷ Ilość osobników na początku pokolenia0: **operator** OPHAREMOWY(*populacja*)1: **var** *rodzice*  $\leftarrow \emptyset$ 2: **var** *kandydaci1*  $\leftarrow \{s : \text{plec}(s) = \sigma, s \in \text{populacja}\}$ 3: **var** *kandydaci2*  $\leftarrow \{s : \text{plec}(s) = \varphi, s \in \text{populacja}\}$ 4: **var** *liczbaZbiorowRodzicow*  $\leftarrow \lceil \text{prawdKrzyzowania} \times \text{rozmiarPopulacji} \rceil$ 5: **var** *liczbaBeta*  $\leftarrow \lceil \text{wspBeta} \times \text{liczbaZbiorowRodzicow} \rceil$ 6: **var** *perAlfa*  $\leftarrow \lceil (\text{liczbaZbiorowRodzicow} - \text{liczbaBeta}) / \text{liczbaAlfa} \rceil$ 7: **for** *i*  $\leftarrow 1$  **to** *liczbaAlfa* **do**8:     **var** *alfa*  $\leftarrow \text{opWyboruAlfa}(\text{kandydaci1})$ 9:     *kandydaci1*  $\leftarrow \text{kandydaci1} \setminus \{alfa\}$ 10:     **for** *j*  $\leftarrow 1$  **to** *perAlfa* **do**11:         **var** *partner*  $\leftarrow \text{opWyboruPartnerow}(\text{kandydaci2})$ 12:         *zbioryRodzicow*  $\leftarrow \text{zbioryRodzicow} \cup \{\{alfa, partner\}\}$ 13:     **end for**14: **end for**15: **for** *i*  $\leftarrow 1$  **to** *liczbaBeta* **do**16:     **var** *beta*  $\leftarrow \text{opWyboruBeta}(\text{kandydaci1})$ 17:     **var** *partner*  $\leftarrow \text{opWyboruPartnerow}(\text{kandydaci2})$ 18:     *rodzice*  $\leftarrow \text{rodzice} \cup \{\{beta, partner\}\}$ 19: **end for**20: **return** *rodzice*21: **end operator**


---



W dalszej kolejności wybierane jest *liczbaBeta* osobników beta (linie 15-16), dla których dobierani są partnerzy *partner* (w linii 17). Tak wybrane pary również dołączane są do zbioru *rodzice* (linia 18).

Operator zwraca zmienną *rodzice* (w linii 20).

Przedstawiony schemat nie zgadza się z sygnaturą operatora selekcji płciowej (sygnaturą 12) przedstawioną w podsekcji 4.1.3, ponieważ w niektórych sytuacjach zwraca więcej par rodziców niż powinien.

Oczekiwany rozmiar zbioru zwracanego przez operator to *liczbaZbiorowRodzicow*, czyli  $\lceil \text{prawdKrzyszowania} \times \text{rozmiarPopulacji} \rceil$ , jednak ponieważ zaokrąglamy wartość *perAlfa* w górę, to często generowane jest *liczbaAlfa* nadmiarowych par. Można temu zaradzić modyfikując ostatnią pętlę, generującą pary z osobnikami beta, w sposób opisany algorytmem 4.4.

---

**Algorytm 4.4** Sposób zaradzenia nadmiarowi zwracanych zbiorów
 

---

```

0: operator OPHAREMOWY(populacja)
1:   (...)
15:  while |rodzice| < liczbaZbiorowRodzicow do
16:    var beta ← opWyboruBeta(kandydaci1)
17:    var partner ← opWyboruPartnerow(kandydaci2)
18:    rodzice ← rodzice ∪ {beta, partner}
19:  end while
20:  return rodzice
21: end operator
  
```

---

Takie podejście powoduje, że parametr *wspBeta* traci swoje dosłowne znaczenie i określa przybliżony stosunek liczby par rodziców zawierających osobniki beta do liczby wszystkich zwracanych par.

W implementacji wykonanej w niniejszej pracy nie zastosowano tej modyfikacji. Umotywowane było to małą różnicą między zakładanym i rzeczywistym rozmiarem zbioru par rodziców, oraz faktem, że *de facto* generowanie nadmiarowych par powoduje minimalnie lepszą eksploatację przestrzeni rozwiązań (ponieważ jest ona gęściej próbkowana).

Jeżeli w populacji występuje więcej niż 2 płcie ( $|\mathcal{G}| > 2$ ), to jedną z nich należy wyróżnić jako tą, z której pochodzą osobniki alfa i beta. Ponadto, operator ma wtedy więcej parametrów (tyle operatorów wyboru partnerów ile jest niewyróżnionych płci), a zamiast jednego partnera (linie 11 i 17) wybiera się ich odpowiednio więcej, każdego z wykorzystaniem przeznaczonego do tego operatora wyboru.



## Rozdział 5

# Eksperymenty

Niniejsza praca ma na celu zbadanie i porównanie różnych podejść do zagadnienia płci wykorzystywanych w algorytmach ewolucyjnych. Aby to osiągnąć zaimplementowano metody opisane w poprzednim rozdziale i przeprowadzono zestaw eksperymentów, których wyniki zostały porównane.

Ten rozdział zaczyna się od prezentacji wybranych problemów optymalizacji, na których przeprowadzone zostały badania. Kolejna sekcja zawiera opis implementacji badanych metod. Następnie omówione są procedury wykorzystywane przy eksperymentach. Całość zamknięta jest podsumowaniem ich przebiegu i przedstawieniem wyników.

### 5.1. Wybrane problemy optymalizacji

#### NP pełność? knapsack to optymalizacja z ograniczeniami

Aby zbadać jakość działania wybranych metod zaimplementowano i podjęto próbę rozwiązania dwóch problemów optymalizacji. Były to problem komiwojażera (*ang. traveling salesman problem*, w skrócie *TSP*) oraz binarny problem plecakowy.

Problem komiwojażera to zadanie znalezienia minimalnego cyklu Hamiltona w pełnym grafie ważonym. Cykl Hamiltona to cykl, w którym każdy wierzchołek jest odwiedzany tylko raz (z pominięciem pierwszego wierzchołka, który jest taki sam jak ostatni). Graf pełny, to taki, w którym między dowolnymi dwoma wierzchołkami istnieje krawędź, a graf ważony to taki, w którym krawędzie opisane są pewnymi wartościami, nazywanymi wagami. Minimalnym cyklem nazywamy taki, dla którego suma wag krawędzi jest najmniejsza.

Problem ten można przełożyć na rzeczywistą sytuację, w której mamy zbiór punktów na mapie (np. miast, reprezentowanych przez wierzchołki grafu) leżących w pewnych odległościach od siebie<sup>1</sup> (które są reprezentowane przez wagi krawędzi). Rozwiązanie problemu komiwojażera sprowadza się do minimalizacji długości drogi przechodzącej przez wszystkie punkty. Wynik optymalizacji jest cenny w rzeczywistych

---

1. Geograficzne odległości między punktami to tylko jedna z możliwych interpretacji. Zamiast tego między punktami może być określony czas przejazdu, jego koszt, itd. W ogólności, znane są pewne wartości związane z każdymi dwoma punktami, które oznaczają tym gorszą sytuację z punktu widzenia osoby rozwiązującej problem, im są wyższe.

zastosowaniach, ponieważ pozwala m.in. zaoszczędzić zasoby w firmach zajmujących się transportem.

Binarny problem plecakowy (nazywany czasem dyskretnym problemem plecakowym) to zadanie optymalizacji, w którym ze zbioru  $n$  par  $\{(k_1, w_1), (k_2, w_2), \dots, (k_n, w_n)\}$  należy wybrać podzbiór, dla którego suma pierwszych elementów z pary będzie jak największa, a suma drugich elementów nie przekroczy zadanej wartości  $W$ . Problem ten przekłada się na sytuację, w której mamy pewien pojemnik (popularnie nazywany plecakiem, skąd bierze się nazwa problemu) o określonej pojemności  $W$  i zestaw przedmiotów, które możemy do niego włożyć. Każdy przedmiot jest opisany parą  $(k, w)$ , gdzie  $k$  reprezentuje jego wartość, a  $w$  jego rozmiar, czy też objętość. Rozwiązaniem problemu jest taki zestaw przedmiotów jaki zmieści się w plecaku i będzie miał jak największą wartość.

Ogólna wersja problemu plecakowego polega na przypisaniu każdemu z przedmiotów (par) liczby naturalnej, określającej ile jego egzemplarzy wkładamy do plecaka, jednak w ramach niniejszej pracy zdecydowano się na binarną wariację tego problemu, która dopuszcza wykorzystanie co najwyżej jednego egzemplarza każdego obiektu.

Opisane problemy zostały wybrane, ponieważ reprezentują dwie klasy zadań powszechnie rozwiązywane przy pomocy algorytmów ewolucyjnych. Binarny problem plecakowy to popularne zadanie w którym rozwiązania są reprezentowane jako wektory bitów, a problem komiwojażera to znane zagadnienie, powszechnie wykorzystywane do badania jakości działania heurystyk. Ponadto, problem plecakowy to zadanie optymalizacji z ograniczeniami, których nie da się łatwo zachować w ramach operatorów genetycznych (w przeciwieństwie np. do problemu komiwojażera, w którym można zastosować operatory, które gwarantują, że zwrócą rozwiązania nie przekraczające ograniczeń, jeżeli osobniki wejściowe ich nie przekraczały).

## 5.2. Implementacja

W tej sekcji opisane są operatory i ich implementacje wykorzystywane podczas przeprowadzania eksperymentów. Pierwsza podsekcja zawiera opis elementów heurystyki niezależnych od problemu, czyli operatorów wyboru i kryterium zarzycania, a kolejne dwie - reprezentacji osobników i operatorów genetycznych wykorzystanych w badaniu wybranych problemów.

### 5.2.1. Komponenty niezależne od problemu

Niezależnie od tego jaki problem jest rozwiązywany przy pomocy algorytmów ewolucyjnych, pewne elementy są niemalże uniwersalne. W tym rozdziale opisane zostaną operatory wyboru oraz kryterium stopu, oraz zestawienie oznaczeń wykorzystywanych w dalszych rozdziałach.

#### Operatory wyboru

Jak zostało zdefiniowane w podsekcji 4.1.2, zadaniem operatora wyboru jest zwrócenie pojedynczego elementu ze zbioru osobników. W standardowych algorytmach ewolucyjnych powszechnie używane są operatory selekcji, które można zaimplementować zgodnie z algorytmem 4.1, korzystające z tego operatora w celu wybrania każdego

ze zwracanych osobników. Ponadto, operatory wykorzystywane w heurystyce DSEA również korzystają z tej abstrakcji.

Jedną z popularnych implementacji operatora wyboru jest **operator ruletkowy** (*ang. roulette select*), wykorzystujący pewną dodatnią funkcję (lub operator) przypisującą każdemu osobnikowi tzw. „wagę”. Zwraca on rozwiązanie z prawdopodobieństwem wprost proporcjonalnym do wartości tej funkcji. Działanie tego operatora standardowo tłumaczy się w następujący sposób: Wyobraźmy sobie koło ruletki. Na całym tym kole zaznaczymy obszary (wycinki koła) przypisane do osobników, w taki sposób, że odpowiedni obszar ma rozmiar wprost proporcjonalny do wagi rozwiązania. Następnie zakręcimy tym kołem, a osobnika, do którego obszar będzie tym, na którym zatrzyma się kulka ruletki, zwrócimy.

Istnieją co najmniej dwie standardowe wersje tego operatora, różniące się funkcją przypisującą wagę osobnikom. Jedną z nich jest ważenie osobników ich oceną. W przypadku problemu maksymalizacji przekłada się to bezpośrednio na wymóg nałożony na standardowy operator selekcji, mówiący o tym, że osobniki „lepsze” mają większą szansę na zostanie wylosowanymi. Odmiana ta jest jednak problematyczna w przypadku problemów minimalizacji, ponieważ „lepsze” osobniki mają wtedy niższą ocenę, a co za tym idzie - zajmują mniej miejsca na wirtualnym kole ruletki, co przekłada się na mniejszą szansę wylosowania. Jeżeli dla danego problemu znana jest górne ograniczenie funkcji oceny (czyli największa wartość pochodząca z jej przeciwdziedziny), to problem minimalizacji możemy przekształcić do problemu maksymalizacji, poprzez zdefiniowanie nowej funkcji oceny, zwracającą wartość oryginalnego kryterium odjętą od jego górnego ograniczenia<sup>2</sup>. W takiej sytuacji, osobniki możemy ważyć przy pomocy ich „rangi”, czyli pozycji po posortowaniu od najgorszych do najlepszych. Dzięki temu najgorszy osobnik zajmuje jedną jednostkę obszaru koła ruletki, drugi - dwie jednostki, a najlepszy -  $n$  jednostek, gdzie  $n$  to rozmiar zbioru na którym stosuje się operator selekcji. Dzięki temu, że operator korzysta jedynie z relacji porządku między osobnikami  $\mathbf{R}_{\triangleleft}$  (wynikającej z relacji porządku określonej na ich ocenach  $\mathbf{R}_{\prec}$ ) nie występuje tu wcześniej opisany problem, więc operator jest użyteczny zarówno w problemach minimalizacji, jak i maksymalizacji.

Schemat działania operatora ruletkowego jest opisany przy pomocy algorytmu 5.1.

Pierwszym krokiem działania operatora jest posortowanie populacji wejściowej tak, aby osobniki o większej wadze (czyli o większym prawdopodobieństwie wyboru) znalazły się bliżej początku posortowanego wektora *posortowane* (w linii 1). Następnie, obliczana jest suma wag wszystkich osobników, przechowywana w zmiennej *sumaWag* (linia 2). W kolejnych krokach wybierana jest losowa wartość *wybrane* z przedziału  $\langle 0, \text{sumaWag} \rangle$  (w linii 3) i inicjalizowana jest zmienna pomocniczna  $k = 0$  (w linii 4). W pętli, rozpoczynającej się w linii 5 przeszukiwany jest wektor *posortowane*, w poszukiwaniu takiego osobnika, którego waga jest mniejsza niż *wybrane* -  $k$ , ale większa lub równa  $k$  (warunek w linii 6). Jeżeli taki osobnik zostanie znaleziony, to zostaje on zwrócony jako wynik działania operatora (linia 7), a w przeciwnym wypadku jego waga zostaje dodana do wartości  $k$  (w linii 9). Jeśli żaden z osobników nie spełnia tych

2. Prosta zmiana znaku kryterium również sprowadza problem minimalizacji do problemu maksymalizacji, jednak nie pozwala na zastosowanie operatora ruletkowego, ponieważ waga osobnika musi być dodatnia. Alternatywne podejście, polegające na użyciu odwrotności wartości kryterium również nie zawsze jest możliwe do użycia, ponieważ wartość oceny może wynosić 0.

**Algorytm 5.1** Schemat działania ruletkowego operatora wyboru**Wejście:***populacja*

▷ Populacja z której wybierany jest osobnik

**Wyjście:**

wybrany osobnik

**Parametry:***waga*

▷ Funkcja wagi, np. funkcja oceny lub ranga


```

0: operator OPRULETKOWY(populacja)
1:   var posortowane  $\leftarrow$  populacja posortowana malejąco po wartości funkcji waga
2:   var sumaWag  $\leftarrow \sum_{s \in \text{populacja}} \text{waga}(s)$ 
3:   var wybrane  $\leftarrow \text{random}(\langle 0, \text{sumaWag} \rangle)$ 
4:   var k  $\leftarrow 0$ 
5:   for  $s \in \text{posortowane}$  do                                     ▷ w kolejności określonej w linii 1
6:     if  $\text{wybrane} \geq k \wedge \text{wybrane} < k + \text{waga}(s)$  then
7:       return s
8:     else
9:        $k \leftarrow k + \text{waga}(s)$ 
10:    end if
11:  end for
12:  return ostatni element posortowane
13: end operator

```

warunków, to zwracany jest ostatni osobnik, z najmniejszą wagą (linia 12).

Rys. 5.1. Działanie ruletkowego operatora wyboru



Działanie tak opisanego operatora obrazuje rysunek 5.1. Na osi zaznaczono przykładowe wagi 3 osobników, w sytuacji w której  $\text{posortowane} = [s_0, s_1, s_2]$  oraz kilka przykładowych wartości ( $a, b, c, d, e$ ) jakie może przyjąć *wybrane*. Jeżeli  $\text{wybrane} = a$  lub  $\text{wybrane} = b$ , to zwrócony zostanie osobnik  $s_0$ , ponieważ  $k$  będzie równe 0 i  $\text{wybrane}$  znajdzie się w odpowiednim przedziale. W przeciwnym wypadku  $k$  zostanie zwiększone do wartości  $\text{waga}(s_0)$ . Wtedy, jeżeli  $\text{wybrane} = c$  lub  $\text{wybrane} = d$ , to zwrócony zostanie osobnik  $s_1$ , z tego samego powodu. Jeżeli jednak  $\text{wybrane} = e$ , to  $k$  przyjmie kolejno wartości  $\text{waga}(s_0) + \text{waga}(s_1)$  i  $\text{waga}(s_0) + \text{waga}(s_1) + \text{waga}(s_2)$ . W takiej sytuacji warunek sprawdzany w pętli nie zostanie spełniony, więc zwrócony zostanie osobnik  $s_2$ .

Drugą powszechnie stosowaną metodą selekcji jest **operator turniejowy** (*ang. tournament select*). Jego działanie polega na wylosowaniu z równym prawdopodobieństwem pewnej ilości osobników i zwróceniu najlepszego spośród nich. Zbiór kandydatów do

zwrócenia nazywa się *turniejem*, a jego rozmiar (czyli ilość rozwiązań które są między sobą porównywane) nazywany jest *rozmiarem turnieju* i jest parametrem operatora.

---

**Algorytm 5.2** Schemat działania turniejowego operatora wyboru
 

---

**Wejście:**  
*populacja*                      ▷ Populacja z której wybierany jest osobnik

**Wyjście:**  
*wynik*                                      ▷ Wybrany osobnik

**Parametry:**  
*n*                                      ▷ Rozmiar turnieju

```

0: operator OPTURNIEJOWY(populacja)
1:   var turniej ← ∅
2:   while |turniej| < n do
3:     turniej ← turniej ∪ random(populacja \ turniej)
4:   end while
5:   var wynik ← NULL
6:   for s ∈ turniej do
7:     if wynik = NULL ∨ (wynik, s) ∈  $\mathbf{R}_{\triangleleft}$  then
8:       wynik ← s
9:     end if
10:  end for
11:  return wynik
12: end operator
  
```

---

Schemat działania operatora turniejowego jest opisany przy pomocy algorytmu 5.1.

Działanie operatora rozpoczyna się od inicjalizacji zbioru *turniej* na zbiór pusty (w linii 1). Następnie, póki zbiór ten nie osiągnie rozmiaru *n* (linia 2) dodawane są do niego osobniki losowo wybierane (bez powtórzeń) z populacji (w linii 3). W kolejnym kroku *turniej* jest przeszukiwany pod kątem rozwiązania lepszego od pozostałych. Polega to na zainicjalizowaniu pomocniczej zmiennej *wynik* na wartość *NULL* (czyli abstrakcyjną, pustą wartość, linia 5) i sprawdzeniu każdego z osobników ze zbioru *turniej* (linia 6). Jeżeli zmienna *wynik* ma wartość *NULL* (czyli pętla dopiero się rozpoczęła) lub rozwiązanie *s* sprawdzane w danym momencie jest lepsze od wartości tej zmiennej (co sprowadza się do sprawdzenia, czy dana para osobników jest w relacji lepszego dopasowania  $\mathbf{R}_{\triangleleft}$ ), to wartość *wynik* jest nadpisywana przez *s* (linie 7 i 8). Wynikiem działania operatora jest znaleziony w ten sposób najlepszy osobnik spośród losowo wybranych, czyli wartość *wynik*, zwracana w linii 11.

### Kryterium stopu

Jak zostało opisane w podsekcji 2.2.7 zadaniem kryterium stopu jest przerwanie działania heurystyki w wybranym momencie. Ma to na celu ograniczenie czasu działania procesu do skończonej wartości.

Najprostszą implementacją tego warunku jest zatrzymanie heurystyki po przetworzeniu określonej liczby pokoleń. Działanie takiego operatora opisane jest przy pomocy algorytmu 5.3

**Algorytm 5.3** Warunek zatrzymania po określonej liczbie pokoleń**Dostępne zmienne:***pokolenie*

▷ Numer obecnego pokolenia, liczony od 1

**Parametry:***max*

▷ Liczba pokoleń które należy przetworzyć

**Wyjście:**

1 oznaczające, że należy przerwać działanie heurystyki, lub 0 w przeciwnym wypadku

0: **operator** KRYTSTOPU1:   **if** *pokolenie* ≤ *max* **then**2:     **return** 13:   **else**4:     **return** 05:   **end if**6: **end operator**

Jego działanie jest trywialne i sprowadza się do sprawdzenia odpowiedniego warunku (w linii 1) i zwrócenia 1 (linia 2) lub 0 (linia 4) w zależności od jego prawdziwości.

**Wykorzystane implementacje i oznaczenia**

W niniejszej pracy wykorzystano operator losowy, ruletkowy ważony rangą, oraz operatory turniejowe o rozmiarze 2 i 3. Wykorzystywane są one wraz z operatorem selekcji naturalnej opisanym algorytmem 4.1 oraz operatorami selekcji płciowej opisanymi za pomocą algorytmów 4.2 i 4.3. Ponadto, niezależnie od eksperymentu wykorzystano kryterium zatrzymania opisane w poprzednim paragrafie.

Tabela 5.1 przedstawia oznaczenia różnych elementów wraz z ich opisem. Przykładowo, zapis  $\text{STDGENSEL}(\top, R, \text{TS}(2))$  oznacza standardowy operator selekcji naturalnej, parametryzowany przez  $\text{plecMaZnaczenie} = \top$ , wykorzystujący operator losowy jako  $\text{opWyboru1}$  i operator turniejowy (z rozmiarem turnieju równym 2) jako  $\text{opWyboru2}$ .

W pracy przyjęto co najwyżej 2 płcie osobników. Jeżeli płć była tylko jedna, to  $\mathcal{G} = \{\odot\}$ , w przeciwnym wypadku  $\mathcal{G} = \{\sigma, \varphi\}$ .

**5.2.2. Implementacja problemu komiwojażera**

Model problemu komiwojażera może zostać przedstawiony w postaci macierzy incydencji grafu reprezentującego rozkład punktów na mapie. Macierz ta (oznaczana jako  $\mathcal{M}_{TSP}$ ) ma wymiary  $p \times p$  gdzie  $p$  to liczba punktów.

$$\mathcal{M}_{TSP} = \begin{pmatrix} m_{1,1} & m_{1,2} & \cdots & m_{1,p} \\ m_{2,1} & m_{2,2} & \cdots & m_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ m_{p,1} & m_{p,2} & \cdots & m_{p,p} \end{pmatrix}$$

Wartość  $m_{x,y}$  oznacza wagę krawędzi łączącej  $x$ ty i  $y$ ty wierzchołek grafu, czyli odległość między punktami o numerach  $x$  i  $y$ .




Tabela 5.1. Oznaczenia operatorów

Oznaczenie	Znaczenie
R	Losowy operator wyboru $random(X)$
RS	Ruletkowy operator wyboru
TS( $n$ )	Turniejowy operator wyboru o rozmiarze turnieju $n$
NATSEL( $X$ )	Operator selekcji naturalnej opisany algorytmem 4.1, korzystający z operatora wyboru $X$
STDGENSEL( $p, W1, W2$ )	Operator selekcji płciowej używany do realizacji dotychczasowych rozwiązań, opisany algorytmem 4.2, parametryzowany przez <code>plecMaZnaczenie</code> = $p$ , <code>opWyboru1</code> = $W1$ oraz <code>opWyboru2</code> = $W2$
HAREM( $a, b, WA, WB, WP$ )	Proponowany haremowy operator selekcji płciowej, opisany algorytmem 4.3 (bez zmian opisanych algorytmem 4.4), wykorzystujący <code>liczbaAlfa</code> = $a$ , <code>wspBeta</code> = $b$ , <code>opWyboruAlfa</code> = $WA$ , <code>opWyboruBeta</code> = $WB$ , <code>opWyboruPartnerow</code> = $WP$ .

Wykorzystano reprezentację osobnika przez pelementowy wektor wartości ze zbioru  $\{1, 2, \dots, p\}$ . Interpretacja tego, że na  $i$ -tej pozycji w wektorze znajduje się wartość  $j$  jest taka, że jako numer  $i$ -tego odwiedzanego punktu wynosi  $j$ .


Przykładowo, dla punktów rozmieszczonych w sposób przedstawiony na rysunku 5.2, osobnik reprezentowany przez wektor  $[1, 6, 4, 5, 3, 2]$  oznacza ścieżkę zaznaczoną na tym samym rysunku przerywaną linią, rozpoczynającą i kończącą się w punkcie 1.

Rys. 5.2. Przykładowe rozwiązanie problemu komiwojażera



Funkcją oceny w tym problemie jest długość ścieżki. Formalnie, `funkcjaOcenyTSP` jest wyrażona jako suma wag krawędzi łączących punkty w kolejności określonej wektorem, co można zapisać w postaci równania 5.1. Pierwsza część równania, występująca przed sumowaniem po odpowiednich indeksach oznacza długość krawędzi między ostatnim, a pierwszym punktem zapisanym w wektorze, dzięki czemu rozwiązania opisujące ścieżki z tą samą kolejnością, ale rozpoczynające się w różnych punktach, np.  $[1, 6, 4, 5, 3, 2]$  i  $[5, 3, 2, 1, 6, 4]$  mają tą samą ocenę.

Rys. 5.3. Przykład działania operatora krzyżowania dla problemu komiwojażera



$$\text{funkcjaOceny}_{TSP}([x_1, x_2, \dots, x_p]) = p_{x_p, x_1} + \sum_{i=1}^{p-1} m_{x_i, x_{i+1}} \quad (5.1)$$

W niniejszej pracy wykorzystano zbiór punktów *sahara* [1] opisujących położenie 29 miast leżących na zachodniej Saharze. Znane jest globalne optimum dla tego zadania, wynoszące 27603.


Wykorzystany operator krzyżowania jest zbliżony do tego opisanego w sekcji 2.1. Polega na wybraniu losowego punktu przecięcia wektorów i wymianie ich podwektorów. Różni się on podanego przykładu tym, że elementy wektorów nie powinny się w nich powtarzać. Aby spełnić to ograniczenie operator tworzy potomków poprzez wykorzystanie pierwszych części wektorów-rodziców i dołączenie do nich niewykorzystanych punktów. Punkty te dołączane są najpierw z podwektora drugiego rodzica za punktem przecięcia, a jeżeli po tym dalej brakuje niektórych z nich, są wybierane od jego początku. Zostało to zobrazowane na rysunku 5.3, gdzie na górze pokazano wektory wejściowe (rodziców), grubą linią zaznaczono punkt przecięcia, a na dole przedstawiono wynik krzyżowania (potomków).

Operator mutacji wykorzystany w tej pracy nosi angielską nazwę *Reverse Sequence Mutation* [2], co można przetłumaczyć na *mutację przez zamianę podciągów*. Jego działanie polega na wybraniu dwóch losowych punktów przecięcia, przez co dzielimy cały wektor na 3 części. Osobnik zmutowany powstaje poprzez zachowanie kolejności elementów w pierwszej i trzeciej części oraz odwrócenie kolejności elementów w drugiej części. Jest to zobrazowane na rysunku 5.4.

### 5.2.3. Implementacja problemu plecakowego

Model binarnego problemu plecakowego można przedstawić w postaci ciągu  $\mathcal{M}_{PLECAK}$   $p$  par  $(k, w)$  oraz wartości  $W$  określającej maksymalny rozmiar plecaka.

Rys. 5.4. Przykład działania operatora mutacji dla problemu komiwojażera



$$\mathcal{M}_{PLECAK} = (((k_1, w_1), (k_2, w_2), \dots, (k_p, w_p)), W)$$

Wartość  $k_i$  oznacza koszt  $i$ tego przedmiotu, a  $w_i$  - jego wagę.

Wykorzystano reprezentację osobnika przez pelementowy wektor binarny (czyli taki, którego wartości to elementy zbioru  $\{0, 1\}$ ). Interpretacja tego, że na  $i$ tej pozycji w wektorze występuje 1 jest taka, że  $i$ ty przedmiot zostaje zapakowany do plecaka, podczas gdy wartość 0 wskazuje na sytuację przeciwną.

Funkcja oceny dla tego problemu jest bardziej skomplikowana niż dla problemu komiwojażera. Główną jej składową jest łączny koszt wszystkich wybranych przedmiotów. Aby sprowadzić problem do problemu minimalizacji<sup>3</sup> jest ona mnożona przez -1. Dodatkowo, aby pokierować heurystyką tak, żeby ograniczenie na łączny rozmiar wybranych przedmiotów było spełnione, wprowadzono funkcję kary, polegającą na dodaniu do funkcji oceny iloczynu łącznego kosztu przedmiotów i różnicy między sumą ich objętości, a maksymalnym rozmiarem plecaka (jeżeli ta różnica jest dodatnia). W ten sposób rozwiązania spełniające ograniczenia mają ocenę równą łącznemu kosztowi z ujemnym znakiem, te, które przekroczyły ograniczenie o 1 mają ocenę równą 0, itd. Zostało to zapisane przy pomocy równań 5.2-5.4.

$$x = [x_1, x_2, \dots, x_p] \quad (5.2)$$

$$\text{funkcjaOceny}_{PLECAK}(x) = (\text{nadmiar}(x) - 1) \times \sum_{i=1}^p (x_i \times k_i) \quad (5.3)$$

$$\text{nadmiar}(x) = \begin{cases} 0 & : \sum_{i=1}^p (x_i \times w_i) \leq W \\ (\sum_{i=1}^p (x_i \times w_i)) - W & : \sum_{i=1}^p (x_i \times w_i) > W \end{cases} \quad (5.4)$$

W tej pracy wykorzystano zbiór *medium* [3], opisujący 100 przedmiotów i maksymalny rozmiar plecaka wynoszący 27. Dla tak przedstawionego zagadnienia znane jest optimum, wynoszące -1137, co oznacza, że wybrane przedmioty mają łączny koszt 1137 i ograniczenie na rozmiar nie jest przekroczone.

3. Zdecydowany się na problem minimalizacji, aby uprościć implementację.

Zastosowano standardowy operator krzyżowania dla wektorów binarnych, opisany w rozdziale 2.1, zobrazowany rysunkiem 2.2. Działa on na zasadzie losowego rozcięcia wektorów na dwa podwektory i zamianie ich drugich części w celu uzyskania potomków.

Wykorzystany operator mutacji to adaptacyjna<sup>4</sup> wariacja na temat operatora przedstawionego w rozdziale 2.1 na rysunku 2.3. W zależności od tego, czy łączna objętość wybranych przedmiotów była większa, czy mniejsza, niż rozmiar plecaka, prawdopodobieństwa tego, że bit zostanie odwrócony (tzn. 0 zostanie zamienione na 1 lub na odwrót) były różne.

Zanim działanie tego operatora zostanie zdefiniowane formalnie, należy opisać pomocniczą funkcję  $rzutuj(x, \langle a, b \rangle)$ , zwracającą punkt leżący w przedziale  $\langle a, b \rangle$  w odległości od obu punktów określonej przez argument  $x$ . Jej definicja jest zapisana w sygnaturze 13.

---

**Sygnatura 13** Funkcja  $rzutuj(\langle a, b \rangle, x)$

---

$$rzutuj : \langle 0, 1 \rangle \times \mathbb{R}^2 \rightarrow \mathbb{R} \quad (5.5)$$

$$rzutuj(x, \langle a, b \rangle) = a + (b - a) \times x \quad (5.6)$$


---

Działanie operatora jest zasadniczo podobne do tego opisanego we wcześniejszym rozdziale - każdy z bitów wektora wejściowego może zostać odwrócony. Prawdopodobieństwo odwrócenia bitu jest zależne od tego, czy jest on równy 0, czy 1, oraz od tego, czy ograniczenie zostało przekroczone, czy też łączny rozmiar wybranych przedmiotów jest mniejszy niż rozmiar plecaka. Pierwsza z tych sytuacji jest umownie nazywana nadmiarem, a druga - niedmiarem.

W ogólności prawdopodobieństwo  $P$  odwrócenia bitu jest wyrażone wzorem 5.7.

$$P = rzutuj(czynnik, przedzial) \quad (5.7)$$

Sposób obliczania wartości *czynnik* jest zależny od sytuacji. Jeżeli obserwowany jest niedmiar, to jego wartość jest różnicą rozmiaru plecaka i sumy rozmiarów wybranych przedmiotów podzieloną przez rozmiar plecaka ( $\frac{W - \sum_{i=1}^p (x_i \times w_i)}{W}$ ), czyli relatywną ilością niewykorzystanego miejsca. Wartość mianownika dla zbadanego problemu to 27 (ponieważ tyle wynosi rozmiar plecaka dla wykorzystanego zbioru danych). Jeżeli natomiast występuje nadmiar, to jest on tożsamy z wartością funkcji  $nadmiar(x)$  (patrz: linia 5.4) podzieloną przez sumę różnicy sumy wszystkich wag i rozmiaru plecaka ( $\frac{nadmiar(x)}{(\sum_{i=1}^p w_i) - W}$ ), czyli wartością nadmiaru znormalizowaną do przedziału  $\langle 0, 1 \rangle$ . W tym przypadku wartość pod kreską ułamkową wynosi 1333, ponieważ suma wag przedmiotów w wybranym zbiorze danych wynosi 1360.

Sposób określania wartości *przedzial* również jest zależny od sytuacji. W tabeli 5.2 przedstawiony jest sposób wyboru odpowiedniego przedziału. Wartości w niej zawarte zostały arbitralnie dobrane tak, aby w sytuacji nadmiaru z większym prawdopodobieństwem odrzucać wybrane przedmioty, a w sytuacji niedmiaru - częściej dobierać nowe.

---

4. Określenie „adaptacyjny” oznacza w tym kontekście, że szczegóły działania operatora zmieniają się w zależności od sytuacji, w której jest wykorzystywany, dopasowując się do napotkanych warunków.

**Tabela 5.2.** Tablica wyboru wartości *przedział*

		Sytuacja	
		Niedmiar	Nadmiar
Wartość bitu	0	$\langle 0.06, 0.1 \rangle$	$\langle 0.05, 0.15 \rangle$
	1	$\langle 0.05, 0.2 \rangle$	$\langle 0.2, 0.7 \rangle$

Intuicyjnie, tak zdefiniowany operator powinien z dużym prawdopodobieństwem zamieniać sytuacje nadmiaru na takie, które spełniają ograniczenia, a przynajmniej powodują znacznie mniejszy nadmiar, a w sytuacji niedmiaru powinien „dopełniać” plecak losowymi przedmiotami, aby uzyskać jak największy zysk (tzn. sumę kosztów przedmiotów).

### 5.3. Procedury eksperymentów

W dalszej części pracy konkretny zestaw parametrów będzie nazywany konfiguracją. Wyrażenie „wynik eksperymentu dla konfiguracji wyniósł  $X$ ” oznacza, że heurystyka została uruchomiona z parametrami (rozmiarem populacji, prawdopodobieństwami, itd.) określonymi przez konfigurację, a jej wynikiem było  $X$ . Należy pamiętać, że algorytm ewolucyjny to heurystyka losowa, więc wynik dla danej konfiguracji za każdym uruchomieniem może być inny.

W ramach badań wykorzystano dwie procedury eksperymentalne, nazywane kolejno procedurą eksploracji (lub krócej, eksploracją) i procedurą przeglądu (odpowiednio, przeglądem).

Pierwsza z nich jest wykorzystywana w sytuacji, w której pojawia się potrzeba przeszukiwania dużej przestrzeni parametrów. Jest to często niemożliwe, ponieważ pojedyncza ewaluacja zestawu parametrów trwa relatywnie długo, a ilość kombinacji wartości parametrów jest zbyt duża.

Aby obejść ten problem, w tej pracy zdecydowano się na iteracyjne podejście przeszukujące przestrzeń konfiguracji wzdłuż wymiarów. Zostało ono wyjaśnione przy pomocy algorytmu 5.4.

**Algorytm 5.4** Procedura eksploracji**Parametry:**

- $X_1, X_2, \dots, X_p$   $\triangleright$  Zestaw  $p$  uporządkowanych zbiorów wartości parametrów  $X_i = [x_{i,1}, x_{i,2}, \dots, x_{i,|X_i|}]$ , gdzie  $x_{i,j}$  to  $j$ ta wartość  $i$ tego parametru
- $R$   $\triangleright$  Ilość nawrotów procedury
- $I$   $\triangleright$  Ilość powtórzeń eksperymentu dla każdej konfiguracji
- statystyka*  $\triangleright$  Operator, przyjmujący zbiór wyników, a zwracający jakąś ich statystykę, np. średnią, medianę wartość minimalną lub maksymalną

**Wejście:**

- cialo*  $\triangleright$  Ciało eksperymentu, tj. operator wykonania pojedynczego eksperymentu, przyjmujący zestaw parametrów  $(P_1, P_2, \dots)$  ( $P_i \in X_i$ ), a zwracający jakąś miarę jakości działania; dla uproszczenia w algorytmie przyjęto, że zwracaną miarę należy zminimalizować.

**Wyjście:**

- konfiguracja*  $\triangleright$  Najlepsza konfiguracja znaleziona w procesie eksploracji, tj.  $p$  wartości  $x_{i,j}$  o różnych indeksach  $i$

```

0: operator EKSPLORUJ(cialo)
1:   var konfiguracja = [ $x_{1,1}, x_{2,1}, \dots, x_{p,1}$ ]
2:   for nawrot  $\leftarrow 1$  to  $R$  do
3:     for parametr  $\leftarrow 1$  to  $p$  do
4:       var statystyki = [ $NULL, NULL, \dots$ ]  $\triangleright$  Tablica o rozmiarze  $|X_{parametr}|$ 
5:       for  $i \leftarrow 1$  to  $|X_{parametr}|$  do
6:         konfiguracja[parametr]  $\leftarrow x_{parametr,i}$ 
7:         var wyniki  $\leftarrow \emptyset$ 
8:         for powtorzenie  $\leftarrow 1$  to  $I$  do
9:           wyniki  $\leftarrow$  wyniki  $\cup \{cialo(konfiguracja)\}$ 
10:        end for
11:        statystyki[ $i$ ]  $\leftarrow$  statystyka(wyniki)
12:      end for
13:      var najlepszaWartosc  $\leftarrow \arg \min_i$  statystyki[ $i$ ]
14:      konfiguracja[parametr]  $\leftarrow x_{parametr,najlepszaWartosc}$ 
15:    end for
16:  end for
17:  return konfiguracja
18: end operator

```

Zapis  $a[b]$  oznacza element tablicy  $a$  o indeksie  $b$

Procedura eksploracji jest zapisana jako operator, ponieważ zwraca pewną wartość (więc nie jest procedurą), która za każdym razem może być inna (więc nie jest funkcją).

Jej działanie zaczyna się od określenia początkowej konfiguracji, czyli zestawu parametrów. W tym celu wykorzystywane są pierwsze elementy każdego z zestawów wartości. Wybór konkretnie tych wartości jest zupełnie arbitralny.

Następnie wykonywane jest  $R$  iteracji nazywanych *nawrotami*. Ma to na celu upew-

nienie się, że dla parametrów wybranych w dalszej części każdego nawrotu wartości wybrane wcześniej faktycznie są jak najlepsze.

W każdym nawrocie badane są wszystkie zestawy wartości parametrów, w kolejności określonej przez parametry procedury. Dla każdego z nich sprawdzane są wszystkie elementy. Dzieje się to przez zmianę odpowiedniej wartości w konfiguracji na element badany w danym momencie.

Po takim podstawieniu ciało eksperymentu wykonywane jest  $I$  razy, a wyniki tych wykonań zbierane są do zbioru *wyniki*. Po odpowiedniej liczbie powtórzeń obliczana jest statystyka tego zbioru. W tym celu wykorzystywany jest parametr procedury *statystyka*. Jej wartość jest zapisywana tak, żeby można było określić dla której wartości parametru została ona określona.

Kiedy wszystkie wartości parametru zostaną zbadane, wybiera się najlepszą z nich, oceniając je po wartości statystyk. Wartość ta zostaje zapisana w konfiguracji używanej do badania kolejnego z parametrów.

referencje do linii

Druga metoda, czyli przegląd zupełny polega na przeszukaniu całego iloczynu kartezjańskiego zestawów wartości parametrów. Jest ona wykorzystywana, kiedy to jakość i miarodajność wyników, a nie czas ich uzyskania ma znaczenie.

przegląd zupełny - formalnie

## 5.4. Przeprowadzone eksperymenty

Badania były przeprowadzane oddzielnie dla każdego problemu. Ich pierwszą częścią było znalezienie początkowej konfiguracji, wykorzystywanej w dalszych etapach. Odbywało się to w dwóch krokach. Pierwszy z nich polegał na znalezieniu parametrów dla standardowego algorytmu ewolucyjnego przy dużej ziarnistości przeszukiwanych wartości, a drugi - na przeszukaniu lokalnego sąsiedztwa konfiguracji znalezionej w kroku pierwszym. W tej części zdarzały się sytuacje w których znaleziono globalne optimum dla problemu, jednak takie zestawy parametrów zostawały odrzucone. Miało to na celu uzyskanie wyników dobrych, ale nie najlepszych, aby sprawdzić, czy w dalszych eksperymentach uda się osiągnąć lepsze rezultaty. Gdyby już na tym etapie znajdowano optimum globalne, nie dałoby się określić, czy nowe rozwiązania poprawiają wyniki.

Drugą częścią badań było zebranie wyników dla DSEA z wykorzystaniem parametrów znalezionych w poprzednim kroku, ale z różnymi implementacjami operatorów selekcji płciowej. Ostatnią ich częścią było odtworzenie wyników dla metod znanych z prac naukowych.

Każdy z tych kroków zostanie opisany oddzielnie, z określeniem rozwiązywanego problemu, zakresem zmienianych parametrów, opisem przebiegu eksperymentu oraz jego najważniejszymi wynikami.

Pełne wyniki eksperymentów są zamieszczone w dodatkach do niniejszego dokumentu.

Kolejne podsekcje opisują przebieg eksperymentów dla problemu komiwojażera i problemu plecakowego, w tej kolejności.

Dla każdego z eksperymentów należało określić (poza rozwiązywanym problemem, a więc reprezentacją osobnika, operatorami genetycznymi i funkcją oceny):

**Algorytm 5.5** name and label me**Parametry:** $X_1, X_2, \dots, X_p$  $I$ *statystyka*

▷ Parametry zdefiniowane w ten sam sposób co dla procedury eksploracji (patrz: algorytm 5.4)

**Wejście:**

*cialo* ▷ Ciało eksperymentu, zdefiniowane w ten sam sposób co dla procedury eksploracji

**Wyjście:**

Najlepsza konfiguracja znaleziona podczas przeglądu zupełnego, tj.  $p$  wartości  $x_{i,j}$  o różnych indeksach  $i$

0: **operator** PRZEGLAD(*cialo*)1: **return** OKRESL(*cialo*,  $(X_1, X_2, \dots, X_p)$ , ())2: **end operator****Wejście:**

*cialo* ▷ Ciało eksperymentu, zdefiniowane w ten sam sposób co dla operatora PRZEGLAD

$(X_n, X_{n+1}, \dots, X_p)$  ▷ Końcowy podciąg zestawu zbiorów wartości parametrów, który należy zbadać

$(p_1, p_2, \dots, p_{n-1})$  ▷ Częściowa konfiguracja, dla której szukane są dalsze parametry z zestawu  $(X_n, X_{n+1}, \dots, X_p)$

**Wyjście:**

Najlepsza konfiguracja znaleziona dla zadanego ciągu

 $(p_1, p_2, \dots, p_{n-1})$ 0: **operator** OKRESL(*cialo*,  $(X_n, X_{n+1}, \dots, X_p)$ ,  $(p_1, p_2, \dots, p_{n-1})$ )1: **var** *statystyki* = [NULL, NULL, ...] ▷ Tablica o rozmiarze  $|X_n|$ 2: **var** *konfiguracje* = [NULL, NULL, ...] ▷ J.w.3: **for**  $i \leftarrow 1$  **to**  $|X_n|$  **do**4: **if**  $n = p$  **then** ▷ Określono wszystkie parametry poza jednym5:  $konfiguracje[i] \leftarrow (p_1, p_2, \dots, p_{n-1}, x_{n,i})$ 6: **else**7: **var** *zbiory*  $\leftarrow (X_{n+1}, X_{n+2}, \dots, X_p)$ 8: **var** *parametry*  $\leftarrow (p_1, p_2, \dots, p_{n-1}, x_{n,i})$ 9:  $konfiguracje[i] \leftarrow OKRESL(cialo, zbiory, parametry)$ 10: **end if**11: **var** *wyniki*  $\leftarrow \emptyset$ 12: **for** *powtorzenie*  $\leftarrow 1$  **to**  $I$  **do**13:  $wyniki \leftarrow wyniki \cup \{cialo(konfiguracje[i])\}$ 14: **end for**15:  $statystyki[i] \leftarrow statystyka(wyniki)$ 16: **end for**17: **var** *najlepszaKonfiguracja*  $\leftarrow \arg \min_i statystyki[i]$ 18: **return** *konfiguracje*[*najlepszaKonfiguracja*]19: **end operator**



- rozmiar populacji (`rozmiarPopulacji`),
- współczynnik domieszek (`wspDomieszek`),
- liczbę pokoleń (parametr kryterium stopu, `max`),
- prawdopodobieństwa mutacji i krzyżowania (`prawdMutacji`, `prawdKrzyzowania`),
- operator selekcji naturalnej (`opSelNat`), definiowany przez wykorzystany operator wyboru,
- operator selekcji płciowej (`opSelPlciowej`), wraz z jego parametrami (zależnymi od implementacji).

Ponadto, korzystając z procedury eksploracji poza powyższymi zbiorami wartości parametrów trzeba było wskazać wartości:

- ilości nawrotów ( $R$ ),
- ilości powtórzeń eksperymentu ( $I$ ), oraz
- statystyki używanej do wyboru dalszej ścieżki eksploracji (*statystyka*).

#### 5.4.1. Badania problemu komiwojażera

W następnych podsekcjach zostaną opisane kolejne kroki badań działania DSEA dla problemu komiwojażera, zdefiniowanego i zaimplementowanego zgodnie z podsekcją 5.2.2.

##### Poszukiwanie parametrów początkowych

**Konfiguracja** W tym kroku wykorzystano procedurę eksploracji w celu znalezienia konfiguracji wyjściowej. W tabeli 1 przedstawiono zbiory wartości parametrów heurystyki i procedury eksploracji użyte w tym kroku.

**Konfiguracja 1.** Wartości wykorzystane podczas poszukiwania parametrów początkowych

Parametr	Zbiór wartości
<code>rozmiarPopulacji</code>	[10, 20, 50]
<code>wspDomieszek</code>	[0, 0,1, 0,25, 0,5]
( <code>prawdKrzyzowania</code> , <code>prawdMutacji</code> )	[0,6, 0,7, 0,8] $\times$ [0,1, 0,2, 0,3]
<code>max</code>	[25, 50, 100]
<code>opSelNat</code>	[ <code>NATSEL(RS)</code> , <code>NATSEL(TS(2))</code> , <code>NATSEL(TS(3))</code> ]

Parametr	Wartość
<code>opSelPlciowej</code>	<code>STDGENSEL(<math>\perp</math>, R, R)</code>
$R$	3
$I$	5
<i>statystyka</i>	najlepszy wynik
Zbiór płci	$\mathcal{G} = \{\odot\}$

**Przebieg** Tabela 5.3 przedstawia przebieg wykorzystanej procedury. Lewa kolumna grupuje znalezione parametry w ramach jednego nawrotu eksploracji. Kolejne dwie, czytane od góry, określają jakie wartości zostały kolejno znalezione.

Jak widać, w pierwszym nawrocie znaleziono prawie najlepszą konfigurację. W drugim, udało się odnaleźć prawdopodobieństwa mutacji i krzyżowania które dawały lepsze wyniki. Trzeci nawrót potwierdził, że znaleziona konfiguracja jest najlepsza z przeszukiwanych.

**Tabela 5.3.** Przebieg procedury eksploracji poszukującej parametrów początkowych


	Parametr	Określona wartość
Nawrót 1	rozmiarPopulacji	50
	wspDomieszek	0,0
	(prawdKrzyzowania, prawdMutacji)	(0,8, 0,3)
	max	100
	opSelNat	NATSEL(RS)
Nawrót 2	rozmiarPopulacji	50
	wspDomieszek	0,0
	(prawdMutacji, prawdKrzyzowania)	(0,6, 0,1)
	max	100
	opSelNat	NATSEL(RS)
Nawrót 3	rozmiarPopulacji	50
	wspDomieszek	0,0
	(prawdMutacji, prawdKrzyzowania)	(0,6, 0,1)
	max	100
	opSelNat	NATSEL(RS)

**Wyniki** Blah, blah, here go results

**Tabela 5.4.** Wyniki heurystyki parametryzowanej znaną konfiguracją

Numer powtórzenia	Wynik	Różnica względem optimum
1	42129,167	14526,167
2	42808,0792	15205,0792
3	36656,3316	9053,3316
4	42174,1093	14571,1093
5	41143,6598	13540,6598
Średnia	40982,2694	13379,2694
Odchylenie standardowe	2227,5198	
Optimum	<b>27603</b>	

Rys. 5.5. Wykres przebiegu trzeciego powtórzenia znalezionej konfiguracji



### Poprawa konfiguracji początkowej

Konfiguracja opisać skąd się wzięły wartości

**Konfiguracja 2.** Wartości wykorzystane podczas poprawy parametrów początkowych

Parametr	Zbiór wartości
rozmiarPopulacji	[40, 45, 50, 55, 60]
wspDomieszek	[0, 0,05, 0,1]
(prawdKrzyzowania,prawdMutacji)	$[0,55, 0,58, 0,6, 0,62, 0,65] \times [0,05, 0,08, 0,1, 0,12, 0,15]$
max	[90, 95, 100, 105, 110]

Parametr	Wartość
opSelNat	NATSEL(RS)
opSelPlciowej	STDGENSEL( $\perp$ , R, R)
$R$	2
$I$	3
statystyka	najlepsza średnia wyników $I$ powtórzeń
Zbiór płci	$\mathcal{G} = \{\odot\}$

Przebieg skomentuj

Tabela 5.5. Przebieg procedury eksploracji poszukującej parametrów początkowych

	Parametr	Określona wartość
Nawrót 1	rozmiarPopulacji	50
	wspDomieszek	0,0
	(prawdKrzyzowania, prawdMutacji)	(0,58, 0,1)
	max	110
Nawrót 2	rozmiarPopulacji	50
	wspDomieszek	0,0
	(prawdKrzyzowania, prawdMutacji)	(0,6, 0,15)
	max	110

Wyniki Blah, blah, here go results

Tabela 5.6. Wyniki heurystyki parametryzowanej poprawioną konfiguracją

Numer powtórzenia	Wynik	Różnica względem optimum
1	39592,0623	11989,0623
2	34292,9277	6689,9277
3	37904,1809	10301,1809
Średnia	37263,0570	9660,0570
Odchylenie standardowe	2707,1178	
Optimum	27603	

poszło lepiej niż init

Konfiguracja 3. Parametry używane w dalszych badaniach

Parametr	Wartość
opSelNat	NATSEL(RS)
opSelPlciowej	STDGENSEL( $\perp$ , R, R)
rozmiarPopulacji	50
wspDomieszek	0,0
prawdKrzyzowania	0,6
prawdMutacji	0,15
max	110

Badania skuteczności heurystyki GGA oraz heurystyki DSEA z podobnym operatorem selekcji płciowej

Konfiguracja blah

**Konfiguracja 4.** Konfiguracja heurystyki GGA

<b>Operator selekcji płciowej</b>	$\text{STDGENSEL}(\top, R, R)$
<b>Operator selekcji naturalnej</b>	$\text{NATSEL}(W)$
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 3
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\sigma, \varphi\}$

Parametr	Zbiór wartości
$W$	$[\text{RS}, \text{TS}(2), \text{TS}(3)]$

**Konfiguracja 5.** Konfiguracja heurystyki DSEA z operatorem podobnym do GGA

<b>Operator selekcji płciowej</b>	$\text{STDGENSEL}(\perp, W, W)$
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 3
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\odot\}$

Parametr	Zbiór wartości
$W$	$[\text{R}, \text{RS}, \text{TS}(2), \text{TS}(3)]$

Wyniki bum bada bim

**Tabela 5.7.** Wyniki heurystyki GGA

W	Ocena
roulette	$68582,5919 \pm 2240,5888$
ts3	$82490,0706 \pm 2235,4966$
ts2	$83291,0773 \pm 1668,8401$

**Tabela 5.8.** Wyniki heurystyki DSEA z operatorem podobnym do GGA

W	Ocena
roulette	$34842,6067 \pm 1284,0574$
random	$37830,7834 \pm 1865,7587$
ts2	$70304,4904 \pm 1770,7225$
ts3	$80423,9968 \pm 1781,7952$

Badania skuteczności heurystyki SexualGA oraz heurystyki DSEA z podobnym operatorem selekcji płciowej

Konfiguracja blah

**Konfiguracja 6.** Konfiguracja heurystyki SexualGA

<b>Operator selekcji płciowej</b>	$\text{STDGENSEL}(\perp, \text{opWyboru1}, \text{opWyboru2})$
<b>Operator selekcji naturalnej</b>	$\text{NATSEL}(R)$
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 3
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\odot\}$

<b>Parametr</b>	<b>Zbiór wartości</b>
opWyboru1	$[\text{TS}(2), \text{TS}(3)]$
opWyboru2	$[\text{RS}, \text{TS}(2), \text{TS}(3)]$

**Konfiguracja 7.** Konfiguracja heurystyki DSEA z jedną płcią z operatorem podobnym do SexualGA

<b>Operator selekcji płciowej</b>	$\text{STDGENSEL}(\perp, \text{opWyboru1}, \text{opWyboru2})$
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 3
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\odot\}$

<b>Parametr</b>	<b>Zbiór wartości</b>
opWyboru1	$[\text{RS}, \text{TS}(2), \text{TS}(3)]$
opWyboru2	$[\text{R}, \text{RS}, \text{TS}(2), \text{TS}(3)]$

**Konfiguracja 8.** Konfiguracja heurystyki DSEA z dwoma płciami z operatorem podobnym do SexualGA

<b>Operator selekcji płciowej</b>	$\text{STDGENSEL}(\top, \text{opWyboru1}, \text{opWyboru2})$
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 3
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\sigma, \varphi\}$

<b>Parametr</b>	<b>Zbiór wartości</b>
opWyboru1	$[\text{RS}, \text{TS}(2), \text{TS}(3)]$
opWyboru2	$[\text{R}, \text{RS}, \text{TS}(2), \text{TS}(3)]$

Wyniki tam da dam

Badania skuteczności heurystyki DSEA z haremowym operatorem selekcji płciowej

Konfiguracja blah

**Tabela 5.9.** Wyniki heurystyki DSEA z jedną płcią, z operatorem podobnym do SexualGA

opWyboru1	opWyboru2	Ocena
roulette	roulette	40199,6226±3708,8267
roulette	random	45328,6013±967,5844
roulette	ts2	50300,0517±3010,3629
roulette	ts3	58433,2242±2810,0883
ts2	roulette	69344,7388±7985,2835
ts3	roulette	73942,4747±2489,2511
ts2	ts2	74102,5322±3456,4116
ts2	random	74439,4152±1775,5433
ts3	random	75138,9453±2567,8802
ts2	ts3	75613,0044±1278,5291
ts3	ts2	76817,7884±4239,8301
ts3	ts3	78242,0359±3940,9643

**Konfiguracja 9.** Konfiguracja heurystyki DSEA z operatorem haremowym

<b>Operator selekcji płciowej</b>	HAREM(a, b, WA, WB, WP)
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 3
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\sigma, \varphi\}$

Parametr	Zbiór wartości
a	[1, 3, 5]
b	[0, 0,1, 0,25]
WA	[R, RS, TS(2), TS(3)]
WB	[R, RS, TS(2), TS(3)]

Parametr	Wartość
WP	R

## Podsumowanie

proza, co wyszło, a co nie

### 5.4.2. Badania problemu plecakowego

W następnych podsekcjach zostaną opisane kolejne kroki badań działania DSEA dla problemu komiwojażera, zdefiniowanego i zaimplementowanego zgodnie z podsekcją ??.

### Poszukiwanie parametrów początkowych

**Konfiguracja** W tym kroku wykorzystano procedurę eksploracji w celu znalezienia konfiguracji wyjściowej. W tabeli 10 przedstawiono zbiory wartości parametrów heurystyki i procedury eksploracji użyte w tym kroku.

**Tabela 5.10.** Wyniki heurystyki DSEA z dwoma płciami, z operatorem podobnym do SexualGA

opWyboru1	opWyboru2	Ocena
roulette	roulette	41555,6377±3146,2442
roulette	random	46760,4675±4193,2035
roulette	ts2	58959,3026±2904,8175
roulette	ts3	60034,4256±2037,1204
ts2	roulette	71987,6709±2285,8795
ts2	ts3	74517,5027±1587,0526
ts3	random	74713,9409±3220,7059
ts2	random	76055,7806±2368,6103
ts2	ts2	76926,4793±5098,4827
ts3	roulette	77571,6168±2876,1054
ts3	ts2	78467,4306±1643,5278
ts3	ts3	78500,7347±2992,6209

**Konfiguracja 10.** Wartości wykorzystane podczas poszukiwania parametrów początkowych

Parametr	Zbiór wartości
rozmiarPopulacji	[10, 20, 50]
wspDomieszek	[0, 0,1, 0,25, 0,5]
(prawdKrzyzowania, prawdMutacji)	[0,6, 0,7, 0,8] × [0,1, 0,2, 0,3]
max	[25, 50, 100]
opSelNat	[NATSEL(RS), NATSEL(TS(2)), NATSEL(TS(3))]

Parametr	Wartość
opSelPlciowej	STDGENSEL( $\perp$ , R, R)
$R$	3
$I$	5
statystyka	najlepszy wynik
Zbiór płci	$\mathcal{G} = \{\odot\}$

**Przebieg** Tabela 5.12 przedstawia przebieg wykorzystanej procedury. Lewa kolumna grupuje znalezione parametry w ramach jednego nawrotu eksploracji. Kolejne dwie, czytane od góry, określają jakie wartości zostały kolejno znalezione.

Jak widać, w pierwszym nawrocie znaleziono prawie najlepszą konfigurację. W drugim, udało się odnaleźć prawdopodobieństwa mutacji i krzyżowania które dawały lepsze wyniki. Trzeci nawrót potwierdził, że znaleziona konfiguracja jest najlepsza z przeszukiwanych.



Tabela 5.11. Wyniki heurystyki DSEA z operatorem haremowym

a	b	WA	WB	Ocena
5	0,1	roulette	random	48915,0643±799,6703
5	0,1	roulette	roulette	49180,7887±4249,2504
3	0,25	roulette	roulette	49744,9081±2768,5553
3	0	roulette	random	49984,0394±3413,5860
5	0,1	roulette	ts3	49985,4366±4012,8489
3	0,25	roulette	random	50011,9993±3104,8017
3	0	roulette	roulette	50296,3335±4102,9637
5	0	roulette	random	50317,9438±3977,9757
3	0,1	roulette	ts3	50425,7944±2674,6857
5	0,25	roulette	roulette	50581,0518±3533,9353
5	0	roulette	ts3	50788,1319±1542,8235
5	0	roulette	ts2	51156,4782±3617,3294

Tabela 5.12. Przebieg procedury eksploracji poszukującej parametrów początkowych


	Parametr	Określona wartość
Nawrót 1	rozmiarPopulacji	50
	wspDomieszek	0,25
	(prawdKrzyzowania, prawdBmutacji)	(0,6, 0,1)
	max	50
	opSelNat	NATSEL(RS)
Nawrót 2	rozmiarPopulacji	50
	wspDomieszek	0,1
	(prawdBmutacji, prawdBkrzyzowania)	(0,8, 0,1)
	max	50
	opSelNat	NATSEL(RS)
Nawrót 3	rozmiarPopulacji	50
	wspDomieszek	0,1
	(prawdBmutacji, prawdBkrzyzowania)	(0,8, 0,1)
	max	50
	opSelNat	NATSEL(RS)

Wyniki Blah, blah, here go results

Tabela 5.13. Wyniki heurystyki parametryzowanej znaną konfiguracją

Numer powtórzenia	Wynik	Różnica względem optimum
1	-1107	66
2	-1156	17
3	-1115	58
4	-1120	53
5	-1173	0
Średnia	-1134,2000	38,8000
Odchylenie standardowe	28,6827	
Optimum	<b>-1173</b>	

Rys. 5.6. Wykres przebiegu piątego powtórzenia znalezionej konfiguracji



### Poprawa konfiguracji początkowej

Konfiguracja opisać skąd się wzięły wartości

**Konfiguracja 11.** Wartości wykorzystane podczas poprawy parametrów początkowych

Parametr	Zbiór wartości
rozmiarPopulacji	[40, 45, 50, 55, 60]
wspDomieszek	[0, 0,05, 0,1, 0,15, 0,2]
(prawdKrzyzowania,prawdMutacji)	[0,75, 0,78, 0,8, 0,82, 0,85] $\times$ [0,05, 0,08, 0,1 0,12, 0,15]
max	[40, 45, 50, 55, 60]

Parametr	Wartość
opSelNat	NATSEL(RS)
opSelPlciowej	STDGENSEL( $\perp$ , R, R)
$R$	2
$I$	3
statystyka	najlepsza średnia wyników $I$ powtórzeń
Zbiór płci	$\mathcal{G} = \{\odot\}$

Przebieg skomentuj

**Tabela 5.14.** Przebieg procedury eksploracji poszukującej parametrów początkowych

	Parametr	Określona wartość
Nawrót 1	rozmiarPopulacji	60
	wspDomieszek	0,1
	(prawdKrzyzowania,prawdMutacji)	(0,75, 0,1)
	max	50
Nawrót 2	rozmiarPopulacji	60
	wspDomieszek	0,1
	(prawdKrzyzowania,prawdMutacji)	(0,75, 0,15)
	max	60

Wyniki Blah, blah, here go results

**Tabela 5.15.** Wyniki heurystyki parametryzowanej poprawioną konfiguracją

Numer powtórzenia	Wynik	Różnica względem optimum
1	-1127	46
2	-1161	12
3	-1131	42
Średnia	-1139,6667	33,3334
Odchylenie standardowe	18,5831	
Optimum	<b>-1173</b>	

poszło lepiej niż init

**Konfiguracja 12.** Parametry używane w dalszych badaniach

Parametr	Wartość
opSelNat	NATSEL(RS)
rozmiarPopulacji	60
wspDomieszek	0,1
prawdKrzyzowania	0,75
prawdMutacji	0,15
max	60

Badania skuteczności heurystyki GGA oraz heurystyki DSEA z podobnym operatorem selekcji płciowej

Konfiguracja **blah**

**Konfiguracja 13.** Konfiguracja heurystyki GGA

Operator selekcji płciowej	STDGENSEL( $\top$ , R, R)
Operator selekcji naturalnej	NATSEL( $W$ )
Pozostałe parametry	Zgodne z konfiguracją 12
Ilość powtórzeń	5
Zbiór płci	$\mathcal{G} = \{\sigma, \varphi\}$

Parametr	Zbiór wartości
$W$	[RS, TS(2), TS(3)]

**Konfiguracja 14.** Konfiguracja heurystyki DSEA z operatorem podobnym do GGA

Operator selekcji płciowej	STDGENSEL( $\perp$ , $W$ , $W$ )
Pozostałe parametry	Zgodne z konfiguracją 12
Ilość powtórzeń	5
Zbiór płci	$\mathcal{G} = \{\odot\}$

Parametr	Zbiór wartości
$W$	[R, RS, TS(2), TS(3)]

Wyniki **bum bada bim**

**Tabela 5.16.** Wyniki heurystyki GGA

W	Ocena
roulette	-1020±115,6045
ts3	-799±154,6803
ts2	-793,4000±234,1893

Tabela 5.17. Wyniki heurystyki DSEA z operatorem podobnym do GGA

W	Ocena
roulette	-1149,8000±16,0674
random	-1068±10,9727
ts3	-744±117,8508
ts2	-135±1174,0538

Badania skuteczności heurystyki SexualGA oraz heurystyki DSEA z podobnym operatorem selekcji płciowej

Konfiguracja **blah**

Konfiguracja 15. Konfiguracja heurystyki SexualGA

Operator selekcji płciowej	STDGENSEL( $\perp$ , opWyboru1, opWyboru2)
Operator selekcji naturalnej	NATSEL(R)
Pozostałe parametry	Zgodne z konfiguracją 12
Ilość powtórzeń	5
Zbiór płci	$\mathcal{G} = \{\odot\}$

Parametr	Zbiór wartości
opWyboru1	[TS(2), TS(3)]
opWyboru2	[RS, TS(2), TS(3)]

Konfiguracja 16. Konfiguracja heurystyki DSEA z jedną płcią z operatorem podobnym do SexualGA

Operator selekcji płciowej	STDGENSEL( $\perp$ , opWyboru1, opWyboru2)
Pozostałe parametry	Zgodne z konfiguracją 12
Ilość powtórzeń	5
Zbiór płci	$\mathcal{G} = \{\odot\}$

Parametr	Zbiór wartości
opWyboru1	[RS, TS(2), TS(3)]
opWyboru2	[R, RS, TS(2), TS(3)]

**Konfiguracja 17.** Konfiguracja heurystyki DSEA z dwoma płciami z operatorem podobnym do SexualGA

<b>Operator selekcji płciowej</b>	$\text{STDGENSEL}(\top, \text{opWyboru1}, \text{opWyboru2})$
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 12
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\sigma, \varphi\}$

Parametr	Zbiór wartości
opWyboru1	[RS, TS(2), TS(3)]
opWyboru2	[R, RS, TS(2), TS(3)]

**Wyniki** tam da dam

**Tabela 5.18.** Wyniki heurystyki DSEA z jedną płcią, z operatorem podobnym do SexualGA

opWyboru1	opWyboru2	Ocena
roulette	roulette	-1152,8000±14,8647
roulette	random	-1143,2000±12,3839
roulette	ts2	-1113,6000±35,9589
ts2	roulette	-1099,4000±13,7492
ts3	roulette	-1074,8000±14,0485
roulette	ts3	-1072±25,7760
ts2	random	-971,8000±107,7616
ts3	random	-899,8000±190,4063
ts2	ts2	-865,4000±196,7095
ts2	ts3	-846±147,8202
ts3	ts2	-794±94,2422
ts3	ts3	-635,6000±123,9009

**Badania skuteczności heurystyki DSEA z haremowym operatorem selekcji płciowej**

**Konfiguracja** blah

**Tabela 5.19.** Wyniki heurystyki DSEA z dwoma płciami, z operatorem podobnym do SexualGA

opWyboru1	opWyboru2	Ocena
roulette	roulette	-1138,6000±20,5777
roulette	random	-1136,2000±20,4783
roulette	ts2	-1105,2000±22,9643
ts3	roulette	-1083,4000±36,9031
ts2	roulette	-1081,4000±32,9460
roulette	ts3	-1080,8000±42,7383
ts2	random	-1010,2000±118,0905
ts3	random	-931,8000±158,7620
ts2	ts2	-824,6000±180,6838
ts2	ts3	-783±263,5967
ts3	ts2	-781,4000±172,7491
ts3	ts3	-633±154,6971

**Konfiguracja 18.** Konfiguracja heurystyki DSEA z operatorem haremowym

<b>Operator selekcji płciowej</b>	HAREM(a, b, WA, WB, WP)
<b>Pozostałe parametry</b>	Zgodne z konfiguracją 12
<b>Ilość powtórzeń</b>	5
<b>Zbiór płci</b>	$\mathcal{G} = \{\sigma, \varphi\}$

Parametr	Zbiór wartości
a	[1, 3, 5]
b	[0, 0,1, 0,25]
WA	[R, RS, TS(2), TS(3)]
WB	[R, RS, TS(2), TS(3)]

Parametr	Wartość
WP	R

**Podsumowanie**

proza, co wyszło, a co nie

**Tabela 5.20.** Wyniki heurystyki DSEA z operatorem haremowym

<b>a</b>	<b>b</b>	<b>WA</b>	<b>WB</b>	<b>Ocena</b>
5	0,25	roulette	roulette	-1144,2000±20,4294
3	0	roulette	ts2	-1142±19,3080
5	0	roulette	ts2	-1141,8000±22,3195
5	0	roulette	ts3	-1134±27,4591
1	0,25	roulette	roulette	-1130,4000±16,2800
5	0,25	roulette	random	-1129±11,3490
5	0	roulette	random	-1128,2000±32,6827
5	0,1	roulette	random	-1128±23,7571
3	0,1	roulette	ts2	-1127,8000±26,4983
3	0,1	roulette	roulette	-1126,6000±8,0647
3	0,25	roulette	ts3	-1125,4000±19,9660
3	0,25	roulette	roulette	-1125,4000±29,6554



## Rozdział 6

# Wnioski i spostrzeżenia



## Rozdział 7

# Dalsze drogi rozwoju

wywalić listy (?)

zmienić styl bibliografii, URL z online resource, uzupełnić linki

znormalizować referencje figure: i vector:

## Spis rysunków

2.1	Ogólny schemat działania algorytmów ewolucyjnych . . . . .	6
2.2	Działanie przykładowej realizacji operatora krzyżowania . . . . .	8
2.3	Działanie przykładowej realizacji operatora mutacji . . . . .	9
2.4	Konwencje dotyczące elementów schematów blokowych . . . . .	11
2.5	Konwencje dotyczące rysowania wykresów . . . . .	12
2.6	Przykładowy wykres przebiegu . . . . .	19
2.7	Wykres przebiegu, w którym globalne optimum nie znajduje się w ostatniej populacji . . . . .	20
2.8	Wykres przebiegu w którym obserwujemy stagnację . . . . .	20
4.1	Schemat działania heurystyki DSEA . . . . .	26
4.2	Szczegóły działania kroku „Wykonaj krzyżowanie” . . . . .	27
4.3	Szczegóły działania kroku „Zadbaj o różnorodność populacji” . . . . .	28
5.1	Działanie ruletkowego operatora wyboru . . . . .	42
5.2	Przykładowe rozwiązanie problemu komiwojażera . . . . .	45
5.3	Przykład działania operatora krzyżowania dla problemu komiwojażera . . . . .	46
5.4	Przykład działania operatora mutacji dla problemu komiwojażera . . . . .	47
5.5	Wykres przebiegu trzeciego powtórzenia znalezionej konfiguracji . . . . .	53
5.6	Wykres przebiegu piątego powtórzenia znalezionej konfiguracji . . . . .	61

# Spis tablic

2.1	Konwencje dotyczące czcionek . . . . .	10
2.2	Opis konwencji dotyczących elementów schematów blokowych . . . . .	11
5.1	Oznaczenia operatorów . . . . .	45
5.2	Tablica wyboru wartości <i>przedział</i> . . . . .	49
1	Wartości wykorzystane podczas poszukiwania parametrów początkowych	52
5.3	Przebieg procedury eksploracji poszukującej parametrów początkowych	52
5.4	Wyniki heurystyki parametryzowanej znalezioną konfiguracją . . . . .	53
2	Wartości wykorzystane podczas poprawy parametrów początkowych	54
5.5	Przebieg procedury eksploracji poszukującej parametrów początkowych	54
5.6	Wyniki heurystyki parametryzowanej poprawioną konfiguracją . . . . .	54
3	Parametry używane w dalszych badaniach	55
4	Konfiguracja heurystyki GGA	55
5	Konfiguracja heurystyki DSEA z operatorem podobnym do GGA	55
5.7	Wyniki heurystyki GGA . . . . .	55
5.8	Wyniki heurystyki DSEA z operatorem podobnym do GGA . . . . .	56
6	Konfiguracja heurystyki SexualGA	56
7	Konfiguracja heurystyki DSEA z jedną płcią z operatorem podobnym do SexualGA	56
8	Konfiguracja heurystyki DSEA z dwoma płciami z operatorem podobnym do SexualGA	57
5.9	Wyniki heurystyki DSEA z jedną płcią, z operatorem podobnym do SexualGA . . . . .	57
5.10	Wyniki heurystyki DSEA z dwoma płciami, z operatorem podobnym do SexualGA . . . . .	58
9	Konfiguracja heurystyki DSEA z operatorem haremowym	58
5.11	Wyniki heurystyki DSEA z operatorem haremowym . . . . .	59
1	Wartości wykorzystane podczas poszukiwania parametrów początkowych	59
5.12	Przebieg procedury eksploracji poszukującej parametrów początkowych	60
5.13	Wyniki heurystyki parametryzowanej znalezioną konfiguracją . . . . .	60
1	Wartości wykorzystane podczas poprawy parametrów początkowych	61
5.14	Przebieg procedury eksploracji poszukującej parametrów początkowych	62
5.15	Wyniki heurystyki parametryzowanej poprawioną konfiguracją . . . . .	62
12	Parametry używane w dalszych badaniach	62
13	Konfiguracja heurystyki GGA	63
14	Konfiguracja heurystyki DSEA z operatorem podobnym do GGA	63
5.16	Wyniki heurystyki GGA . . . . .	63
5.17	Wyniki heurystyki DSEA z operatorem podobnym do GGA . . . . .	63
15	Konfiguracja heurystyki SexualGA	64
16	Konfiguracja heurystyki DSEA z jedną płcią z operatorem podobnym do SexualGA	64
17	Konfiguracja heurystyki DSEA z dwoma płciami z operatorem podobnym do SexualGA	64

5.18 Wyniki heurystyki DSEA z jedną płcią, z operatorem podobnym do SexualGA . . . . .	65
1Konfiguracja heurystyki DSEA z operatorem haremowym	65
5.19 Wyniki heurystyki DSEA z dwoma płciami, z operatorem podobnym do SexualGA . . . . .	66
5.20 Wyniki heurystyki DSEA z operatorem haremowym . . . . .	66
A.1 Pełne wyniki dla konfiguracji D . . . . .	79
A.1 Pełne wyniki dla konfiguracji D . . . . .	80
A.1 Pełne wyniki dla konfiguracji D . . . . .	81
A.1 Pełne wyniki dla konfiguracji D . . . . .	82
A.1 Pełne wyniki dla konfiguracji D . . . . .	83
A.2 Pełne wyniki dla konfiguracji D . . . . .	83
A.2 Pełne wyniki dla konfiguracji D . . . . .	84
A.2 Pełne wyniki dla konfiguracji D . . . . .	85
A.2 Pełne wyniki dla konfiguracji D . . . . .	86



# Spis sygnatur

1	Operator $random(S)$ . . . . .	13
2	Osobnik . . . . .	13
3	Funkcja oceny . . . . .	14
4	Operator mutacji . . . . .	14
5	Operator krzyżowania . . . . .	15
6	Operator selekcji . . . . .	16
7	Warunek zatrzymania i jego przykładowa realizacja . . . . .	16
8	Funkcja $plec(osobnik)$ . . . . .	25
9	Osobnik w kontekście DSEA . . . . .	26
10	Operator selekcji naturalnej . . . . .	30
11	Operator wyboru . . . . .	30
12	Operator selekcji płciowej . . . . .	32
13	Funkcja $rzutuj(\langle a, b \rangle, x)$ . . . . .	48





# Spis algorytmów

2.1	Szczegółowy schemat działania kroku "Wykonaj krzyżowanie" . . . . .	17
2.2	Szczegółowy schemat działania kroku "Wykonaj mutację" . . . . .	17
2.3	Szczegółowy schemat działania kroku "Dokonaj selekcji naturalnej" . .	18
4.1	Schemat działania operatora selekcji naturalnej korzystającego z operatora wyboru . . . . .	31
4.2	Schemat działania wybranych operatorów selekcji płciowej . . . . .	33
4.3	Schemat działania operatora haremowego . . . . .	36
4.4	Sposób zaradzenia nadmiarowi zwracanych zbiorów . . . . .	37
5.1	Schemat działania ruletkowego operatora wyboru . . . . .	42
5.2	Schemat działania turniejowego operatora wyboru . . . . .	43
5.3	Warunek zatrzymania po określonej liczbie pokoleń . . . . .	44
5.4	Procedura eksploracji . . . . .	50



# Bibliografia

- [1] Western sahara tsp dataset.
- [2] Abdoun O., Abouchabaka J., Tajani C. Analyzing the performance of mutation operators to solve the travelling salesman problem. *arXiv preprint arXiv:1203.3099*, 2012.
- [3] Barker W.
- [4] Cramer N. L. A representation for the adaptive generation of simple sequential programs. W: *Proceedings of the First International Conference on Genetic Algorithms*, s. 183–187, 1985.
- [5] Davis L. et al. *Handbook of genetic algorithms*, volume 115. Van Nostrand Reinhold New York, 1991.
- [6] Lindenfors P., Tullberg B., Biuw M. Phylogenetic analyses of sexual selection and sexual size dimorphism in pinnipeds. *Behavioral Ecology and Sociobiology*, 52(3):188–193, 2002.
- [7] Rejeb J., AbuElhaij M. New gender genetic algorithm for solving graph partitioning problems. W: *Circuits and Systems, 2000. Proceedings of the 43rd IEEE Midwest Symposium on*, volume 1, s. 444–446 vol.1, 2000.
- [8] Streeter M., Becker L. Automated discovery of numerical approximation formulae via genetic programming. *Genetic Programming and Evolvable Machines*, 4(3):255–286, 2003.
- [9] Wagner S., Affenzeller M. SexualGA: Gender-specific selection for genetic algorithms. W: *WMSCI 2005 - The 9th World Multi-Conference on Systemics, Cybernetics and Informatics, Proceedings*, volume 4, s. 76–81, Institute for Formal Models and Verification, Johannes Kepler University, 2005.



## Dodatek A

# Pełne wyniki badań

### A.1. Oceny uruchomień

**DIS**

### A.2. Średnia i odchylenie standardowe ocen

#### A.2.1. Problem komiwojażera

Pełne wyniki dla konfiguracji A, B i C zostały przedstawione w tabelach (kolejno) ??, ?? i ??.

**Tabela A.1.** Pełne wyniki dla konfiguracji D

a	b	WA	WB	Ocena
1	0	random	random	63148,9662±2991,8179
1	0	random	roulette	66670,9717±1262,9803
1	0	random	ts2	66796,5075±6059,7659
1	0	random	ts3	68187,0807±2149,1036
1	0	roulette	random	57076,8068±4343,3643
1	0	roulette	roulette	54775,3531±5638,5163
1	0	roulette	ts2	56340,1414±6044,4863
1	0	roulette	ts3	54006,4018±4598,4399
1	0	ts2	random	75308,7970±3633,9511
1	0	ts2	roulette	74997,8832±2935,5700
1	0	ts2	ts2	76741,2555±2242,8727
1	0	ts2	ts3	77503,6281±1581,0616
1	0	ts3	random	76519,0885±2253,6313
1	0	ts3	roulette	72779,5574±5353,2170
1	0	ts3	ts2	75175,3784±3301,5956
1	0	ts3	ts3	78434,3927±2954,2537

**Tabela A.1.** Pełne wyniki dla konfiguracji D

a	b	WA	WB	Ocena
1	0,1	random	random	64921,6141±6697,8244
1	0,1	random	roulette	64153,5248±5337,5054
1	0,1	random	ts2	63998,2593±4514,1330
1	0,1	random	ts3	67860,9913±4007,6007
1	0,1	roulette	random	58860,1927±4668,3636
1	0,1	roulette	roulette	56876,6204±6087,3432
1	0,1	roulette	ts2	59168,2933±6028,8071
1	0,1	roulette	ts3	58552,7445±3943,3595
1	0,1	ts2	random	72711,4148±2242,7582
1	0,1	ts2	roulette	72285,5698±3099,3636
1	0,1	ts2	ts2	75258,9438±2953,5893
1	0,1	ts2	ts3	77276,6458±2694,4933
1	0,1	ts3	random	77111,6797±3828,9922
1	0,1	ts3	roulette	71349,2091±4878,2432
1	0,1	ts3	ts2	77586,9380±3119,5781
1	0,1	ts3	ts3	78069,6955±3673,5858
1	0,25	random	random	66994,8520±4023,6182
1	0,25	random	roulette	60997,5136±6205,8751
1	0,25	random	ts2	67909,2289±4366,4780
1	0,25	random	ts3	73214,5627±3249,9024
1	0,25	roulette	random	53644,9562±7782,7804
1	0,25	roulette	roulette	53808,7353±4046,0390
1	0,25	roulette	ts2	62118,5620±5688,0029
1	0,25	roulette	ts3	59549,6937±2079,0981
1	0,25	ts2	random	71167,9756±3467,9171
1	0,25	ts2	roulette	69516,4694±3857,5267
1	0,25	ts2	ts2	75792,7275±1612,9532
1	0,25	ts2	ts3	74832,2360±3382,2709
1	0,25	ts3	random	74964,2607±2349,6463
1	0,25	ts3	roulette	69979,4438±3583,5517
1	0,25	ts3	ts2	76249,6930±3824,2332
1	0,25	ts3	ts3	75990,2492±2912,9578
3	0	random	random	62868,0769±7751,6167
3	0	random	roulette	56121,6305±3989,7036
3	0	random	ts2	59093,8247±3117,2364
3	0	random	ts3	63458,2872±7104,6750
3	0	roulette	random	49984,0394±3413,5860
3	0	roulette	roulette	50296,3335±4102,9637
3	0	roulette	ts2	54536,6127±2073,5921
3	0	roulette	ts3	52536,3872±2990,5480
3	0	ts2	random	73484,4181±3885,8193
3	0	ts2	roulette	74478,1926±2587,2221

**Tabela A.1.** Pełne wyniki dla konfiguracji D

<b>a</b>	<b>b</b>	<b>WA</b>	<b>WB</b>	<b>Ocena</b>
3	0	ts2	ts2	72856,6152±3474,1592
3	0	ts2	ts3	73092,2391±2272,5163
3	0	ts3	random	76931,2121±1800,5863
3	0	ts3	roulette	75135,6567±4431,5355
3	0	ts3	ts2	75682,9234±2832,6889
3	0	ts3	ts3	76114,5387±1810,1806
3	0,1	random	random	66262,8388±5674,1525
3	0,1	random	roulette	60593,4130±5125,6922
3	0,1	random	ts2	65170,9779±4340,9190
3	0,1	random	ts3	61336,7695±3620,2601
3	0,1	roulette	random	51363,5478±2794,6387
3	0,1	roulette	roulette	52016,5879±2570,3068
3	0,1	roulette	ts2	52803,6719±6387,9210
3	0,1	roulette	ts3	50425,7944±2674,6857
3	0,1	ts2	random	76918,4637±1665,1880
3	0,1	ts2	roulette	70565,4907±2366,5805
3	0,1	ts2	ts2	77198,5539±3053,2183
3	0,1	ts2	ts3	74259,2851±3365,5329
3	0,1	ts3	random	74865,9696±2581,8355
3	0,1	ts3	roulette	73903,8469±2491,2040
3	0,1	ts3	ts2	76308,3468±3078,2639
3	0,1	ts3	ts3	76997,8103±1211,5696
3	0,25	random	random	59556,0633±2987,8681
3	0,25	random	roulette	58191,3987±5601,6655
3	0,25	random	ts2	65240,4898±3467,4363
3	0,25	random	ts3	65138,9060±4347,0213
3	0,25	roulette	random	50011,9993±3104,8017
3	0,25	roulette	roulette	49744,9081±2768,5553
3	0,25	roulette	ts2	53467,0572±4345,7140
3	0,25	roulette	ts3	60171,9765±5147,0004
3	0,25	ts2	random	71438,2157±3586,8758
3	0,25	ts2	roulette	68006,9848±4026,1532
3	0,25	ts2	ts2	74497,9470±1554,6735
3	0,25	ts2	ts3	74656,9039±2367,0028
3	0,25	ts3	random	73530,5451±2698,0934
3	0,25	ts3	roulette	67962,9038±7004,1249
3	0,25	ts3	ts2	76363,9840±1606,0915
3	0,25	ts3	ts3	76312,6057±3891,0184
5	0	random	random	60117,0561±4072,2315
5	0	random	roulette	58179,4247±5016,6409
5	0	random	ts2	61515,5684±5409,0071
5	0	random	ts3	59911,1642±5244,0632

**Tabela A.1.** Pełne wyniki dla konfiguracji D

a	b	WA	WB	Ocena
5	0	roulette	random	50317,9438±3977,9757
5	0	roulette	roulette	53504,5557±3707,6132
5	0	roulette	ts2	51156,4782±3617,3294
5	0	roulette	ts3	50788,1319±1542,8235
5	0	ts2	random	74580,7985±1077,5927
5	0	ts2	roulette	75713,6243±2142,5180
5	0	ts2	ts2	75054,2396±1911,7425
5	0	ts2	ts3	74089,8740±1555,1333
5	0	ts3	random	75462,3438±4243,4037
5	0	ts3	roulette	76150,5022±3311,8237
5	0	ts3	ts2	76807,2873±936,1096
5	0	ts3	ts3	74233,3135±2016,9396
5	0,1	random	random	61931,3831±2601,7142
5	0,1	random	roulette	58728,0221±5575,6031
5	0,1	random	ts2	61491,1380±3006,6230
5	0,1	random	ts3	61139,5114±5231,7141
5	0,1	roulette	random	48915,0643±799,6703
5	0,1	roulette	roulette	49180,7887±4249,2504
5	0,1	roulette	ts2	52655,6111±3701,1865
5	0,1	roulette	ts3	49985,4366±4012,8489
5	0,1	ts2	random	75777,1455±3011,2519
5	0,1	ts2	roulette	74311,1839±3015,2988
5	0,1	ts2	ts2	75941,6041±1817,5820
5	0,1	ts2	ts3	74369,8617±1720,6807
5	0,1	ts3	random	75279,7935±1623,1280
5	0,1	ts3	roulette	73428,8700±2606,5743
5	0,1	ts3	ts2	77422,1984±3077,9164
5	0,1	ts3	ts3	76189,8794±1242,9144
5	0,25	random	random	59716,8629±3202,3405
5	0,25	random	roulette	58548,4801±3387,6080
5	0,25	random	ts2	64768,1599±3676,9758
5	0,25	random	ts3	65020,3398±4697,9745
5	0,25	roulette	random	51738,6886±4413,3552
5	0,25	roulette	roulette	50581,0518±3533,9353
5	0,25	roulette	ts2	52485,3787±6491,9936
5	0,25	roulette	ts3	56627,3107±2048,8223
5	0,25	ts2	random	72289,2530±3353,1352
5	0,25	ts2	roulette	69823,4881±2625,8599
5	0,25	ts2	ts2	72289,4172±3478,8958
5	0,25	ts2	ts3	76573,3110±1902,9758
5	0,25	ts3	random	74021,7512±3492,0954
5	0,25	ts3	roulette	72185,1169±3426,1645



**Tabela A.1.** Pełne wyniki dla konfiguracji D

a	b	WA	WB	Ocena
5	0,25	ts3	ts2	74201,3036±1228,9679
5	0,25	ts3	ts3	78413,6345±1917,3845

**A.2.2. Problem plecakowy**

Pełne wyniki dla konfiguracji A, B i C zostały przedstawione w tabelach (kolejno) ??, ?? i ??.

**Tabela A.2.** Pełne wyniki dla konfiguracji D

a	b	WA	WB	Ocena
1	0	random	random	-1012,8000±131,2774
1	0	random	roulette	-1084,2000±18,6269
1	0	random	ts2	-1098,8000±25,2063
1	0	random	ts3	-1051,8000±140,9190
1	0	roulette	random	-1110,2000±32,7744
1	0	roulette	roulette	-1072,6000±15,9198
1	0	roulette	ts2	-1109±19,7180
1	0	roulette	ts3	-1098,2000±52,8371
1	0	ts2	random	-867,2000±129,1440
1	0	ts2	roulette	-988,4000±124,0461
1	0	ts2	ts2	-986,2000±125,2173
1	0	ts2	ts3	-999,2000±129,5290
1	0	ts3	random	-889,8000±185,3423
1	0	ts3	roulette	-994±124,9928
1	0	ts3	ts2	-997±124,5664
1	0	ts3	ts3	-1025,4000±128,4361
1	0,1	random	random	-1062,2000±22,9556
1	0,1	random	roulette	-1075,2000±20,7210
1	0,1	random	ts2	-1078,8000±53,7044
1	0,1	random	ts3	-1010,6000±133,3696
1	0,1	roulette	random	-1102,6000±29,5675
1	0,1	roulette	roulette	-1112±23,9833
1	0,1	roulette	ts2	-1117,6000±41,6346
1	0,1	roulette	ts3	-1072,6000±45,3943
1	0,1	ts2	random	-1063,8000±58,3520
1	0,1	ts2	roulette	-1070,2000±42,2535
1	0,1	ts2	ts2	-1001±115,2406
1	0,1	ts2	ts3	-935,4000±178,3172
1	0,1	ts3	random	-990±125,4400

**Tabela A.2.** Pełne wyniki dla konfiguracji D

<b>a</b>	<b>b</b>	<b>WA</b>	<b>WB</b>	<b>Ocena</b>
1	0,1	ts3	roulette	-920,2000±141,5732
1	0,1	ts3	ts2	-1002,4000±139,6919
1	0,1	ts3	ts3	-909,8000±129,1780
1	0,25	random	random	-1112,2000±21,3860
1	0,25	random	roulette	-1104,8000±27,2720
1	0,25	random	ts2	-1052±138,4124
1	0,25	random	ts3	-1038,8000±30,1025
1	0,25	roulette	random	-1105±22,1450
1	0,25	roulette	roulette	-1130,4000±16,2800
1	0,25	roulette	ts2	-1097±18,4716
1	0,25	roulette	ts3	-1114±25,8457
1	0,25	ts2	random	-1054,6000±37,7020
1	0,25	ts2	roulette	-1085,4000±20,2445
1	0,25	ts2	ts2	-993,4000±137,6541
1	0,25	ts2	ts3	-994,4000±128,2070
1	0,25	ts3	random	-1044,4000±35,8251
1	0,25	ts3	roulette	-1078,6000±35,3757
1	0,25	ts3	ts2	-914,6000±120,8679
1	0,25	ts3	ts3	-801,8000±121,1799
3	0	random	random	-1006,4000±120,2973
3	0	random	roulette	-1100,2000±24,5063
3	0	random	ts2	-1109,8000±18,0488
3	0	random	ts3	-1068,8000±30,4920
3	0	roulette	random	-1120,4000±20,1851
3	0	roulette	roulette	-1123,8000±6,6151
3	0	roulette	ts2	-1142±19,3080
3	0	roulette	ts3	-1107,8000±12,5762
3	0	ts2	random	-945,6000±157,4847
3	0	ts2	roulette	-943,2000±140,0077
3	0	ts2	ts2	-923,6000±149,8794
3	0	ts2	ts3	-1005,8000±125,0238
3	0	ts3	random	-931,6000±158,7509
3	0	ts3	roulette	-923±152,6145
3	0	ts3	ts2	-863±182,5190
3	0	ts3	ts3	-820,4000±115,2486
3	0,1	random	random	-1094,8000±25,9492
3	0,1	random	roulette	-1096±57,6299
3	0,1	random	ts2	-1097,8000±5,9800
3	0,1	random	ts3	-1065,2000±52,9354
3	0,1	roulette	random	-1104±19,8192
3	0,1	roulette	roulette	-1126,6000±8,0647
3	0,1	roulette	ts2	-1127,8000±26,4983

**Tabela A.2.** Pełne wyniki dla konfiguracji D

<b>a</b>	<b>b</b>	<b>WA</b>	<b>WB</b>	<b>Ocena</b>
3	0,1	roulette	ts3	-1110,2000±31,4859
3	0,1	ts2	random	-1060,6000±27,5289
3	0,1	ts2	roulette	-1031±130,1845
3	0,1	ts2	ts2	-1015,4000±124,2926
3	0,1	ts2	ts3	-1015,8000±113,7249
3	0,1	ts3	random	-1016,4000±122,7218
3	0,1	ts3	roulette	-941,4000±152,9844
3	0,1	ts3	ts2	-919,6000±134,2723
3	0,1	ts3	ts3	-869±177,8033
3	0,25	random	random	-1082±28,5937
3	0,25	random	roulette	-1098,4000±12,1260
3	0,25	random	ts2	-1078,4000±29,3843
3	0,25	random	ts3	-1077±27,4809
3	0,25	roulette	random	-1105,8000±16,8095
3	0,25	roulette	roulette	-1125,4000±29,6554
3	0,25	roulette	ts2	-1119,8000±5,5642
3	0,25	roulette	ts3	-1125,4000±19,9660
3	0,25	ts2	random	-945,6000±161,4764
3	0,25	ts2	roulette	-1114,6000±14,4859
3	0,25	ts2	ts2	-1015,6000±143,9592
3	0,25	ts2	ts3	-944,4000±154,4624
3	0,25	ts3	random	-1002±139,9328
3	0,25	ts3	roulette	-1092±15,5820
3	0,25	ts3	ts2	-933,8000±165,6676
3	0,25	ts3	ts3	-959±167,7319
5	0	random	random	-1105,4000±27,9614
5	0	random	roulette	-1112,2000±19,9439
5	0	random	ts2	-1074,8000±26,5435
5	0	random	ts3	-1113,4000±36,4395
5	0	roulette	random	-1128,2000±32,6827
5	0	roulette	roulette	-1116,6000±24,1959
5	0	roulette	ts2	-1141,8000±22,3195
5	0	roulette	ts3	-1134±27,4591
5	0	ts2	random	-1032,4000±144,6024
5	0	ts2	roulette	-1117,8000±28,4211
5	0	ts2	ts2	-1027,2000±25,3724
5	0	ts2	ts3	-1093,4000±36,6093
5	0	ts3	random	-1045±23,1948
5	0	ts3	roulette	-1045,2000±51,3241
5	0	ts3	ts2	-923,8000±141,9358
5	0	ts3	ts3	-889±156,8630
5	0,1	random	random	-1112,4000±22,8438

**Tabela A.2.** Pełne wyniki dla konfiguracji D

<b>a</b>	<b>b</b>	<b>WA</b>	<b>WB</b>	<b>Ocena</b>
5	0,1	random	roulette	-1112,8000±43,1620
5	0,1	random	ts2	-1104±38,1733
5	0,1	random	ts3	-1080,2000±40,5630
5	0,1	roulette	random	-1128±23,7571
5	0,1	roulette	roulette	-1121,6000±20,3627
5	0,1	roulette	ts2	-1111,2000±18,5731
5	0,1	roulette	ts3	-1091±41,9285
5	0,1	ts2	random	-1088,8000±54,2011
5	0,1	ts2	roulette	-1001,4000±119,2486
5	0,1	ts2	ts2	-1014,2000±124,6891
5	0,1	ts2	ts3	-1001,8000±123,5919
5	0,1	ts3	random	-991,8000±135,3328
5	0,1	ts3	roulette	-1052,2000±14,3304
5	0,1	ts3	ts2	-961,2000±155,8979
5	0,1	ts3	ts3	-940,6000±158,9548
5	0,25	random	random	-1106,6000±14,4582
5	0,25	random	roulette	-1101,2000±16,9635
5	0,25	random	ts2	-1072,8000±19,9339
5	0,25	random	ts3	-1099±30,7181
5	0,25	roulette	random	-1129±11,3490
5	0,25	roulette	roulette	-1144,2000±20,4294
5	0,25	roulette	ts2	-1113,8000±17,0575
5	0,25	roulette	ts3	-1102,8000±31,0123
5	0,25	ts2	random	-1080,6000±12,7530
5	0,25	ts2	roulette	-1105±17,7426
5	0,25	ts2	ts2	-967,6000±162,3645
5	0,25	ts2	ts3	-932±156,8528
5	0,25	ts3	random	-1074,6000±34,4244
5	0,25	ts3	roulette	-1063,4000±30,9296
5	0,25	ts3	ts2	-893,4000±154,3847
5	0,25	ts3	ts3	-866,4000±135,5649